

Sem vložte zadání Vaší práce.

ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ V PRAZE
FAKULTA INFORMAČNÍCH TECHNOLOGIÍ
KATEDRA SOFTWAREVÉHO INŽENÝRSTVÍ



Diplomová práce

Adaptibilní systém pro doporučování obsahu

Bc. Jan Bouchner

Vedoucí práce: Ing. Jaroslav Kuchař

29. dubna 2014

Poděkování

Chci upřímně poděkovat všem, kteří mi věnovali čas, když jsem potřeboval pomoc při psaní této diplomové práce, především vedoucímu práce Ing. Jaroslavu Kuchaři za správné směrování, celkový vhled do technologií a cenné komentáře. Děkuji také své rodině a všem přátelům za bezvýhradnou podporu během celých mých studií.

Prohlášení

Prohlašuji, že jsem předloženou práci vypracoval(a) samostatně a že jsem uvedl(a) veškeré použité informační zdroje v souladu s Metodickým pokynem o etické přípravě vysokoškolských závěrečných prací.

Beru na vědomí, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., autorského zákona, ve znění pozdějších předpisů. V souladu s ust. § 46 odst. 6 tohoto zákona tímto uděluji nevýhradní oprávnění (licenci) k užití této mojí práce, a to včetně všech počítačových programů, jež jsou její součástí či přílohou a veškeré jejich dokumentace (dále souhrnně jen „Dílo“), a to všem osobám, které si přejí Dílo užít. Tyto osoby jsou oprávněny Dílo užít jakýmkoli způsobem, který nesnižuje hodnotu Díla a za jakýmkoli účelem (včetně užití k výdělečným účelům). Toto oprávnění je časově, teritoriálně i množstevně neomezené. Každá osoba, která využije výše uvedenou licenci, se však zavazuje udělit ke každému dílu, které vznikne (byť jen zčásti) na základě Díla, úpravou Díla, spojením Díla s jiným dílem, zařazením Díla do díla souborného či spracováním Díla (včetně překladu), licenci alespoň ve výše uvedeném rozsahu a zároveň zpřístupnit zdrojový kód takového díla alespoň srovnatelným způsobem a ve srovnatelném rozsahu, jako je zpřístupněn zdrojový kód Díla.

V Praze dne 29. dubna 2014

.....

České vysoké učení technické v Praze
Fakulta informačních technologií

© 2014 Jan Bouchner. Všechna práva vyhrazena.

Tato práce vznikla jako školní dílo na Českém vysokém učení technickém v Praze, Fakultě informačních technologií. Práce je chráněna právními předpisy a mezinárodními úmluvami o právu autorském a právech souvisejících s právem autorským. K jejímu užití, s výjimkou bezúplatných zákonných licencí, je nezbytný souhlas autora.

Odkaz na tuto práci

Bouchner, Jan. *Adaptibilní systém pro doporučování obsahu*. Diplomová práce. Praha: České vysoké učení technické v Praze, Fakulta informačních technologií, 2014.

Abstract

Sem doplňte ekvivalent abstraktu Vaší práce v angličtině.

Keywords Nahradte seznamem klíčových slov v angličtině oddělených čárkou.

Abstrakt

V několika větách shrňte obsah a přínos této práce v češtině. Po přečtení abstraktu by se čtenář měl mít čtenář dost informací pro rozhodnutí, zda chce Vaši práci číst.

Klíčová slova Nahradte seznamem klíčových slov v češtině oddělených čárkou.

Obsah

Úvod	1
Lidstvo a informace	1
Doporučovací systémy	3
Motivace	4
Cíle práce	4
Struktura práce	5
1 Aktuální stav na poli doporučování	7
1.1 Příklady systémů	7
1.2 Shrnutí poznatků	14
2 Analýza a návrh řešení	15
2.1 Požadavky	15
2.2 Adaptibilní systém	17
2.3 Architektura systému	18
2.4 Rozhraní	23
2.5 Sada algoritmů	25
3 Adaptibilní systém	27
3.1 Minimální teoretický základ	27
3.2 Význam strojového učení při návrhu systému	31
3.3 Multi-armed Bandits algoritmus	33
3.4 Bayesian Bandits	34
4 Realizace	37
4.1 Principy a technologie	37
4.2 Popis realizace adaptibilního systému	43
4.3 Popis realizace RESTful API	51
4.4 Popis realizace sady algoritmů	51

5 Experimenty a vyhodnocení	53
5.1 Testování různých způsobů chování	53
5.2 Experimenty	53
5.3 Zhodnocení aplikace	53
5.4 Budoucí práce	53
Závěr	55
Literatura	57
A Seznam použitých zkratk	61
B Obsah přiloženého CD	63

Seznam obrázků

0.1	Příklad rozdělení zobrazující popularitu hodnocení	3
1.1	Abstraktní model open source systému easyrec	13
2.1	Abstraktní pohled na systém společnosti plista	18
2.2	Abstraktní návrh architektury a komponent adaptibilního systému	19
2.3	Příklad MQ systému s producentem zpráv a konzumenty	20
2.4	Ukázka REST endpointů navrhovaného adaptibilního systému . .	23
3.1	Vizualizace sekvenčního učení řešení od jedné do tisíce her.	36
4.1	Vícevláknový server s využitím ROUTER a DEALER.	47

Úvod

We are leaving the age of information and entering the age of recommendation.

—CHRIS ANDERSON, 2004

Hned na úvod práce jsem si dovilil použít citát z článku *The Long Tail* [15] bývalého šéfredaktora časopisu Wired, Chrise Andersona, který je též autorem stejnojmenné teorie. Ta je založena na tom, že díky rozvoji internetu lze nabízet daleko širší paletu produktů, se kterými lze slavit prodejní úspěchy, což by dříve kvůli nízké poptávce nebylo možné.

Co je myšleno tvrzením „které by dříve mohly jen sotva slavit prodejní úspěchy“? Myšlenky se lze dopátrat v následující sekci Lidstvo a informace, po kterémžto vysvětlení bude vše zasazeno do kontextu zmiňované teorie (podsekce Informace a The Long Tail Theory) a její souvislosti s potřebou doporučování informací, jež je popsána v sekci Doporučovací systémy.

Sekce Motivace popisuje vizi a potřebu systému schopného přizpůsobit se podmínkám a predikovat doporučení na základě předchozích a aktuálních zkušeností.

Popisu nároků na takový systém, jenž jsem prostřednictvím této práce navrhl a následně implementoval, je věnována sekce Cíle práce. V sekci jsou též stanoveny cíle, kterých by měl implementovaný produkt nabývat.

Struktuře práce vzhledem k vytyčeným cílům je věnována příslušná sekce Struktura práce.

Lidstvo a informace

Význam sběru informací a dat je pro lidstvo odjakživa nezpochybnitelný. Již před nástupem digitálního věku byl jejich objem značný a dostat se ke všem informacím, na základě kterých by byl jedinec schopen utvořit si vlastní názor, nebylo dvakrát tak snadné.

Lidé se tak v mnoha případech spoléhali spíše na obecnou oblíbenost daného produktu (zboží, článek, hudební interpret a další), než na vlastní úsudek. Oblíbenost produktu byla přitom více než cokoliv jiného určována aktuálním společenským trendem.

Informace bylo dále možné v omezené míře čerpat například z doporučení známých pramenících z jejich zkušeností.

Nástup internetu

S masovým rozvojem internetu začalo růst množství dostupných informací obřím tempem (organizace IDC došla v článku *Extracting Value from Chaos* [26] k závěru, že objem světových dat se každé dva roky zdvojnásobuje).

Nové informace jsou produkovány takřka každou sekundu a na jejich seřazení máme mnohem méně času než kdy dříve. Není již v lidských silách udržovat si o všem přehled.

Takovýmto vývojem se přirozeně změnil i pohled na data. Cílem již není shromáždit jich co nejvíce, neboť tímto pokusem bychom se zanedlouho dostali až do stavu informačního zahlcení.

Ceněným uměním je nyní schopnost vytěžit maximální množství užitečných informací a ty využít k nabytí nových vědomostí a získat tak alespoň přibližně správnou odpověď na potřeby konkrétního jedince.

Informace a The Long Tail Theory

Vraťme se nyní ještě jednou k teorii The Long Tail. Pro účely této práce nemá smysl vysvětlovat její význam dopodrobna, nicméně je vhodné zmínit alespoň hlavní myšlenku vycházející z úvah výše v textu.

Nejdůležitějším poznatkem z pohledu obchodního je to, že s nárůstem informací dochází ke snižování prodeje produktů, které dříve určoval trend (několik málo produktů, které se na daném trhu dostaly k masovému publiku) ve prospěch produktů nacházejících se v takzvaném dlouhém chvostu (the long tail).

Uživatel samotný se tak může dopátrat informací, na které by obyčejným vyhledáváním neměl šanci nikdy narazit (za předpokladu, že by opravdu přesně nevěděl, co nebo koho hledá).

Bližší představu si lze utvořit pohledem na obrázek 0.1. Představme si, že na vodorovné ose leží jednotlivé produkty. Svislá osa pak znázorňuje objem prodeje pro dané produkty (stejně tak se může jednat například o popularitu). Zelená část pod grafem nalevo znázorňuje těch několik dominujících produktů (označuje se též jako *hlava*). Žlutá část pod grafem vpravo pak reprezentuje dlouhý chvost (zhruba 80 procent produktů, po kterých je na trhu poptávka v menších objemech).



Obrázek 0.1: Příklad rozdělení zobrazující popularitu hodnocení. Zdroj: <http://en.wikipedia.org/> [35]

Tento fenomén lze dost dobře ilustrovat na příkladu hudebního průmyslu. Díky obrovským databázím ¹ hudebních interpretů a skladeb již nedochází k selekci a prodeji/poslechu zlomku těch potenciálně nejúspěšnějších. Uživatelé jsou konfrontováni s mnohem širším výběrem a je pouze na nich, kterého interpreta či skladbu si k poslechu zvolí.

Všechny výše zmiňované faktory přirozeným způsobem zapříčinily rozvoj přístupu zvaného *informační filtrování*. Tedy jakési selekce a redukce informací na základě volených parametrů. Odtud už je pak jen krok k doporučování obsahu uživateli na míru, které se v posledních několika letech rozmáhá se zaváděním tzv. *doporučovacích systémů*.

Doporučovací systémy

Doporučovací systém je druh inteligentního systému, jenž je svému uživateli nápomocný v tom smyslu, že z obrovské množiny informací dokáže různými způsoby filtrovat pro něj relevantní podmnožinu. Tato filtrace probíhá na základě zkoumání určitých vlastností uživatelského profilu (z minulosti i současnosti).

Typy systémů

Doporučovací systémy lze dělit do dvou skupin dle způsobu práce, jíž vykonávají.

Kolaborativní filtrování. Do první skupiny patří systémy fungující na principu takzvaného kolaborativního filtrování. Tento princip má navíc ještě

¹Spotify, last.fm, Groovespark, Google Music a řada dalších

dvě odnože liší se dle toho, zda je doporučování založeno na podobnosti uživatelů (User-based) či podobnosti položek (Item-based).

Doporučení z této skupiny nejčastěji využívají stránky zabývající se prodejem různých produktů.

Doporučení založená na obsahu. Druhou skupinou jsou doporučení založená na obsahu. Pro ty se nejčastěji využívá textové podobnosti. Výhodou systémů využívajících doporučení z této skupiny je rychlé absorbování nových položek. Již na malé množině dat lze dostávat poměrně uspokojivá doporučení.

Další informace týkající se doporučovacích systémů lze načerpat z následující kapitoly 1. Technické detaily jsou pak v menší míře k nalezení v sekci 4.4 kapitoly 4.

Motivace

Představme si rádce, který je v každém okamžiku schopen rozhodnout, co je pro nás za daných okolností nejvhodnější.

To, o čem rádce rozhoduje, je volba algoritmu, jakým si má uživatel nechat v danou chvíli doporučit obsah. Pokud by uživatel dbal rádcových rad, pak by s největší pravděpodobností obdržel vhodné doporučení a svou spokojenost by vyjádřil například tím, že by si jednu z doporučených položek otevřel pro bližší zkoumání nebo by ji ohodnotil na škále od jedné do pěti.

Rádce neprovádí žádné operace, dokud k nim není explicitně vyzván uživatelem. Jinými slovy vyčkává na okamžik, kdy je požádán o radu.

Jeho hlavním benefitem je to, že dokáže pružně reagovat na situaci, při níž dojde k náhlé změně preferencí konzumace obsahu nebo vyvstanou jiné neočekávané události, jež by jinak měly za následek dlouhodobější doporučování nevhodného obsahu.

Cíle práce

Cílem práce je vyvinout aplikaci vykazující podobné znaky chování jako rádce popsany výše.

Nejdůležitějším cílem této práce je tedy návrh a implementace adaptibilního systému, který by byl schopen automaticky a vhodně kombinovat metody pro doporučování obsahu. Metodami jsou zde zamýšleny algoritmy pro doporučování obsahu (výběr vhodné sady algoritmů je též jedna ze součástí této práce).

Systém bude dále zpracovávat zpětnou vazbu od uživatelů ohledně kvality zvoleného doporučení, která principem odměny za dobré doporučení nebo trestu za špatné ovlivní preference při kombinování.

Systém bude zároveň zodpovědný za poskytování podpory většímu množství uživatelů zasílajících žádosti na systém.

Nezbytnou součástí diplomové práce je též osvojení základních pojmů a pravidel z oblasti strojového učení, teorie pravděpodobnosti a statistiky užívaných zejména v části zabývající se predikcí vhodného algoritmu a dopadem zpětné vazby.

Vzhledem k povaze projektu bude nutné navrhnout obecné rozhraní jak pro manipulaci s doporučovacími algoritmy, tak pro adaptibilní systém (zahrnující též zpětnou vazbu).

Funkčnost navrženého systému bude ověřena implementací prototypu a jeho spuštěním na modelové úloze.

Následuje seznam modulů, které byly pro potřeby práce vyvinuty:

- **adaptibilní systém pro doporučování obsahu**
- **sada základních algoritmů určených k doporučování**
- **obecné rozhraní pro manipulaci s doporučovacími algoritmy a systémem**
- **generátor dokumentů, pomocí kterých byly prováděny experimenty**

Struktura práce

Tato práce je strukturována do pěti různých kapitol a popisuje celý vývojový cyklus systému. Kapitoly jsou řazeny v pořadí, v jakém probíhaly jednotlivé fáze vývoje.

Kapitola Aktuální stav na poli doporučování popisuje historické pozadí i trendy používané současnými doporučovacími systémy. Z této rešerše se snaží vyvodit některé závěry, jež by mohly být užitečné pro náplň některé z dalších kapitol.

Kapitola Analýza a návrh řešení shromažďuje veškeré požadavky kladené na systém, dále se zabývá návrhem architektury, detailními návrhy serverové i klientské části, rozhraním zastřešujícím komunikaci těchto částí a výběrem základní sady algoritmů, které budou využity k doporučování obsahu.

Kapitola Adaptibilní systém detailně popisuje algoritmické a matematické postupy použité při návrhu adaptibilního systému.

Kapitola Realizace popisuje vývoj aplikace na základě provedené analýzy a návrhu.

Kapitola Experimenty a vyhodnocení shrnuje poznatky nabyté z provedených experimentů se systémem a hodnotí vyvinutou aplikaci.

Aktuální stav na poli doporučování

V dnešní moderní době je možné setkat se s celou řadou různých doporučení.

- lidé, které byste mohli znát
- uživatelé kupující produkt X kupují též produkt Y
- položky podobné položce XY

Jak vidno, doporučení nesou různá označení, všechny však sdílejí stejnou myšlenku – zaujmout či upozornit na něco či někoho konkrétního. Spousta elektronických obchodů, renomovaných aukčních domů, ale též serverů se zábavou na nich doslova staví své podnikání, neboť správně navržený a fungující doporučovací systém může přinést výrazné navýšení zisku.

Sami firemní zákazníci navíc o doporučení stojí. Uspadňuje jim navigaci po stránce a existuje zde vysoká šance, že na jeho základě přizpůsobí své chování.

Nicméně důvěra uživatele v navštívenou stránku je tak velká, jak dobrá doporučení stránka poskytuje. Pokud zákazník dostává samá špatná doporučení, nenásleduje je a ve výsledku odmítá celý systém.

1.1 Příklady systémů

Na internetu lze narazit na desítky, ba i stovky systémů zapojených do reálného provozu. Záměrně jsem se snažil vybrat pouze zlomek, jenž ale zároveň pokrývá většinu typů doporučovaného obsahu (produkty, články, zábava apod.).

1.1.1 Amazon.com

Amazon.com, Inc. ² je jedním z největších a nejstarších internetových prodejců. Společnost začínala jako online knihkupectví, postupem let však zařadila do své prodejní nabídky též hudební a filmové nosiče, software, elektroniku, nábytek a spoustu dalšího zboží včetně vlastní spotřební elektroniky v podobě čtečky elektronických knih a tabletů Kindle či poskytování služeb z oblasti cloud computingu.

Firmu lze řadit mezi průkopníky doporučování na internetu. Jako jeden z prvních internetových prodejců začala svým zákazníkům doporučovat výrobky na základě nákupů jiných uživatelů.

Doporučovací systém společnosti je založen na více zdrojích informací:

- porovnávání uživatelem prohlížených položek a položek umístěných uvnitř nákupního košíku s položkami, které se společně s těmito prohlíženými položkami v minulosti často prodávaly ³.
- uchovávání informací ohledně hodnocení položek uživateli
- zaznamenávání nákupní historie (Pokud uživatel v minulém měsíci zakoupil tři dětské knížky, znamená to, že má dítě?)
- sledování spousty dalších postupů, jako například vyhodnocování demografických informací (dle doručovací adresy), zaznamenávání pohybu po stránce (jaké všechny položky si uživatel prohlédl, než vložil jednu konkrétní do nákupního košíku) nebo sledování prokliků ⁴ z marketingových e-mailů s odkazy na zboží [4].

Společnost užívá jako svou hlavní doporučovací strategii *item-to-item ko-laborativní filtrování*. Fanoušek moderních technologií tak může při návštěvě stránek nalézt odkazy na technologické novinky všeho druhu, zatímco mladá matka bude mít v nabídce té samé stránky ve větší míře zastoupeno dětské zboží.

Výše jsou samozřejmě popsány pouze základní principy. Doporučovací systém společnosti jako takový je velmi komplexní a detaily algoritmu jsou drženy jako obchodní tajemství. K nahlédnutí jsou ale patenty, např. *Personalized recommendations of items represented within a database* [24] nebo *Collaborative recommendations using item-to-item similarity mappings* [27].

²<http://www.amazon.com>

³affinity analysis – nacházení spojení mezi odlišnými položkami. Základním příkladem budiž vztah mezi šamponem a kondicionérem. Kupující je většinou používá v ten samý čas [11]. Při nákupu jednoho by mohl mít tedy zájem i o druhý.

⁴Jako proklik se označuje takové kliknutí na odkaz, které uživatele dovede na cílovou stránku [10].

1.1.2 Netflix

Netflix, Inc. ⁵ je společnost, poskytující v začátcích své služby jako internetová videopůjčovna, jež se v průběhu posledních několika let rozrostla v obrovskou mediální společnost. Strategicky významným byl pro ni rok 2007. Tehdy byla nabídka jejích služeb rozšířena o filmy přenášené přes stream ⁶ [8]. Nyní společnost nabízející obsah v podobě filmů a seriálů pro většinu v dnešní době používaných platforem jako PC, Mac, PlayStation3, Wii, Xbox a také pro mobilní telefony a tablety.

Vzhledem k tomu, že firma staví své podnikání na tom, že její zákazníci ji platí za konzumaci zábavy, je v jejím vlastním zájmu, aby těmto uživatelům sledujícím filmy a seriály nabízela automaticky další obsahově či žánrově podobné, zkrátka takové, jež budou co možná nejvíce lahodit jejich vkusu (dle [7] pochází $\frac{2}{3}$ zapůjčených filmů na Netflix z předchozího doporučení). Úspěšné podnikání společnosti je tak přímo závislé na tom, jak kvalitním doporučovací systém společnost disponuje.

1.1.2.1 Netflix Prize

[30] Za tímto účelem vyvinula společnost vlastní systém *Cinematch* napomáhající svým zákazníkům objevit pro ně zajímavé filmy. Postupný vývoj na poli doporučovacích systémů však přivedl společnost na otázku, zda není možné vyvinout systém, jež by dokázal Cinematch v oblasti předpovídání filmového vkusu porazit. Společnost tak vypsala začátkem října 2006 soutěž známou jako *Netflix Prize*. Týmu, kterému by se podařilo zlepšit dosavadní výsledky systému Cinematch alespoň o 10 procent, by byla přiřknuta odměna ve výši 1 milion amerických dolarů.

Do soutěže byla uvolněna sada testovacích dat obsahující:

- ID uživatele
- ID filmu
- hodnocení na intervalu $\langle 1, 5 \rangle$
- datum uskutečnění hodnocení

Data obsahovala 100 480 507 takových hodnocení pro 17 770 filmů od 480 189 uživatelů. Uvolněna byla ještě další sada testovacích dat obsahující stejné informace, jen s vynecháním uživatelských hodnocení. Cílem pak bylo predikovat tato chybějící hodnocení opět na intervalu $\langle 1, 5 \rangle$.

Celková výhra byla udělena až v roce 2009 (do té doby sice docházelo k průběžnému zlepšování výsledků, nikdy však nebylo dosaženo požadovaného

⁵<https://www.netflix.com>

⁶Snímek se fyzicky nenachází na koncovém zařízení, ale přehrává se přímo ze serveru poskytovatele .

zlepšení 10 procent) týmu *BellKor's Pragmatic Chaos*, vzniklého spojením tří do té doby samostatně soutěžících týmů.

Vítězný tým dosáhl cíle pomocí pokročilých technik strojového učení. Zjistil přitom především to, že hodnocení každého filmu je silně subjektivní záležitostí, kterou je velmi obtížné programově předpovědět. Ukázalo se také, že ve větší míře záleží na tom, zda uživatel hodnotí právě dosledovaný film nebo film, který zhlédl již před delší dobou. Velkou roli hraje i nálada uživatele v průběhu dne a další faktory [1].

Výsledný algoritmus, jenž získal cenu, vznikl kombinováním zhruba stovky menších algoritmů. S trochou nadsázky lze tedy prohlásit, že jednou z hlavních taktik pro kvalitní doporučení je použití tolika algoritmů, kolik je jen možné.

1.1.3 Zite

Zite.com⁷ je moderní aplikace pro chytré mobilní telefony a tablety.

Mike Klass (CTO společnosti) v jednom z článků [12] prozradil, že vizí bylo vyvinout sofistikovaný, na technikách strojového učení založený systém, jehož účelem nebude pouhé filtrování přichozích novinek, ale především přizpůsobení se svému uživateli studiem vzorců chování (pozorováním zájmů a návyků při čtení článků). Cílem bylo přizpůsobit se uživateli natolik, aby mu bylo možné doporučit přesně to, co v danou chvíli hledá, ale kvůli různým okolnostem (obsah produkováný neznámým bloggerem apod.) by na to nikdy neměl šanci narazit.

Zite nasazené v systému uživatele je tedy stejně tak unikátní jako jeho uživatel. Každý den vyhodnocuje miliony nových článků, přičemž se zaměřuje na typ, klíčové atributy i na to, jakým způsobem je článek sdílen skrze web. Následně využije tyto informace ke spárování vybraných článků s osobním vkusem uživatele a tyto články mu doručí do aplikace.

Tak jako Netflix a Amazon doporučují filmy a produkty, které by na základě podobnosti mohly být pro uživatele zajímavé, stejně tak i Zite provádí na pozadí různá porovnání čtenářských profilů – jak v rámci aplikace, tak na webu – a vytváří doporučení.

1.1.3.1 Zite & CNN & Flipboard

V srpnu 2011 o technologii vyjádřila zájem společnost CNN [2] a Zite přešlo pod ni. Poslední novinky ze začátku března 2014 ale naznačují [12], že Zite opouští CNN a rozhodlo se spojit síly s aplikací Flipboard⁸ vývojářské společnosti Flipboard, Inc., jejíž funkcionalitou je agregování obsahu ze sociálních sítí a jiných stránek a následná nabídka ke čtení v magazínovém formátu umožňujícím jednoduchým způsobem listovat napříč vzájemně souvisejícími tématy.

⁷<http://zite.com>

⁸<https://flipboard.com>

Společným cílem je vystavět nejlepší systém pro personalizované čtení novinových zpráv.

1.1.4 Mendeley

Mendeley ⁹ je systém určený k doporučování vědeckých článků využívající jako svou výpočetní vrstvu technologii Apache Mahout ¹⁰. Cílem systému je spojovat dohromady výzkumníky a jejich data. Svým uživatelům napomáhá v organizaci výzkumu, umožňuje jim navázat potenciální spolupráci s dalšími uživateli aplikace a napomáhá též k objevení nových podnětů pro vlastní práci. Uživatelé této aplikace jsou přední světové university jako University of Cambridge, Stanford University, MIT či University of Michigan. Data pro aplikaci pocházejí z vlastních importů uživateli i z externích importů skrze různé katalogy vědeckých prací.

Projekt samotný se v jedné ze svých prezentací [6] přirovnává k největší hudební databázi na internetu – last.fm ¹¹. Ta funguje na principu, že potenciální uživatel provede na svém počítači instalaci desktopové aplikace, následně s již instalovanou aplikací začne poslouchat hudbu a tím je zahájeno automatické odesílání informace o skladbě (interpret, žánr) na server last.fm. Podle dat odeslaných na server jsou uživateli v budoucnu doporučovány další skladby.

Mendeley tuto analogii vysvětluje tak, že hudební knihovny jsou v jeho případě výzkumné knihovny, role interpretů zastávají jednotliví výzkumníci, hudební skladby jsou pak jimi publikované články a jednotlivé hudební žánry reprezentují vědecké disciplíny.

Doporučení jsou dle dostupných informací [6] generována dvojím způsobem.

Kolaborativní filtrování Používá se pro personalizované doporučení. Podporována je jak user-based, tak item-based varianta.

Filtrování založené na obsahu Používá se k nalezení souvisejících výzkumů, například pro nalezení článku ze stejné výzkumné kategorie nebo článku majícího podobný název.

Uživatelé vyjadřují svůj zájem či nezájem o každou z doporučených položek zpětnou vazbou, která je dvojího typu:

Accept vyjadřuje, že uživatel s daným doporučením souhlasí nebo pro něj bylo nějakým způsobem užitečné.

Remove vyjadřuje nevhodné doporučení. Uživatel touto volbou dává najevo, že podobné doporučení by příště již raději nedostal.

⁹<http://www.mendeley.com>

¹⁰<https://mahout.apache.org>

¹¹<http://www.last.fm>

1.1.5 Google News

Vlastní platformu pro doporučování obsahu vytvořila v rámci svého vývoje též společnost **Google, Inc.**¹². Její výzkumníci se v práci [28] zabývali vývojem prediktivního systému pro personalizované doporučování zpráv na webu Google News¹³.

Přihlášeným uživatelům, majícím v prohlížeči explicitně povolen záznam historie prohlížení, jsou generována doporučení založená na zájmu těchto uživatelů, která vycházejí z různých profilů sestavených pozorováním chování uživatelů na stránce.

K porozumění, jak se mění zájem uživatelů o zprávy v čase, napomohla výzkumníkům analýza logů (záznamy chování anonymních uživatelů na stránce). Na základě této analýzy byl vyvinut Bayesovský framework pro předvídání zájmu uživatelů o zveřejňované novinky.

Kombinace mechanismu pro filtraci informací vzešlého z nashromážděných uživatelských profilů a již existujícího mechanismu využívajícího principů kolaborativního filtrování vedla ke vzniku systému generujícího personalizovanou nabídku zpráv. Vzniklá kombinace byla nasazena do reálného provozu a následné experimenty prokázaly, že kombinováním metod došlo ke zlepšení kvality doporučování.

1.1.6 Výzkum

Také současný výzkum v oblasti doporučovacích systémů, zdá se, nezahálí. Zde je výčet několika akcí, jejichž náplní či součástí je problematika doporučování a doporučovacích systémů.

- **ACM RecSys conference.**¹⁴ Konference je předním mezinárodním fórem pro prezentaci nových výsledků výzkumu a postupů na poli doporučovacích systémů. RecSys sdružuje hlavní mezinárodní výzkumné skupiny a též mnoho předních světových společností na trhu e-commerce. Nabízí také doprovodný program v podobě zvaných přednášek, konzultace týkající se problematiky RecSys a sympóziu studentů doktorských programů.

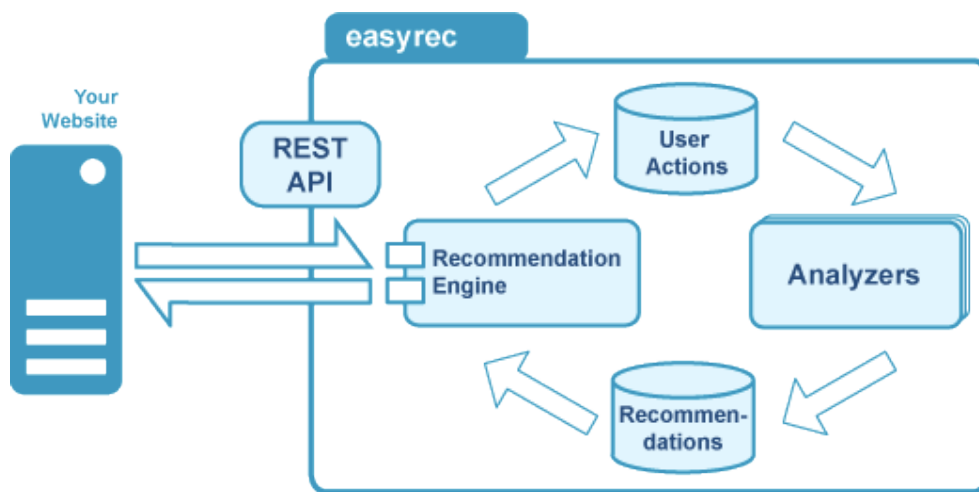
Zajímavé prezentace jsou volně dostupné na internetu, dá se tedy načerpat spousta inspirace do vlastního výzkumu. Mě osobně velmi zaujala prezentace¹⁵ z posledního ročníku konference (Hong Kong, 2013), se kterou vystoupil Torben Brodt, jeden z klíčových řečníků. V prezentaci popisuje tzv. *Open Recommendation Platform*, která je založena na výběru vždy toho nejlepšího algoritmu pro doporučení v závislosti na daném kontextu.

¹²<http://www.google.com/about/company>

¹³<http://news.google.com>

¹⁴<http://recsys.acm.org>

¹⁵<http://www.slideshare.net/d0nut/open-recommendation-platform>



Obrázek 1.1: Abstraktní model open source systému easyrec. Zdroj: [3]

- **ICWSM: Weblog and Social Media.** ¹⁶ The International AAAI Conference on Weblogs and Social Media je mezinárodní konference, na které se střetávají výzkumní pracovníci z oblasti počítačových a společenských věd. Konference je pořádána za účelem sdílení znalostí, diskutování o nápadech a výměny informací. Probíranými body jsou psychologické a sociální teorie, výpočetní algoritmy pro analýzu sociálních médií a jedním z mnoha témat jsou též doporučovací systémy.

O tématu se též píše spousta článků a každým rokem vzniká několik disertačních prací. Dle dostupných informací z ACM RecSys Wiki ¹⁷ jich jen za poslední 4 roky bylo přes 50.

Technická knihovna společnosti IBM obsahuje přehledný seznam ¹⁸ několika doporučovacích systémů, z nichž převážná část vznikla jakou součástí univerzitního výzkumu.

Z tohoto seznamu se mi jako velmi zajímavý systém jeví systém *easyrec* ¹⁹. Jedná se o open source webovou aplikaci napsanou v programovacím jazyce Java nabízející personalizovaná doporučení prostřednictvím RESTful webových služeb. Prostřednictvím REST API je možné zasílat uživatelské akce jako prohlížení, nákup či hodnocení položky. Tyto uživatelské akce jsou poté ukládány do databáze easyrec, nad kterou je prováděna analýza a z té jsou generována doporučení pro aplikaci vyvíjenou uživatelem (viz obrázek 1.1).

¹⁶<http://www.icwsm.org/2014>

¹⁷http://www.recsyswiki.com/wiki/List_of_recommender_system_dissertations

¹⁸<http://www.ibm.com/developerworks/library/os-recommender2/index.html>

¹⁹<http://easyrec.org/recommendation-engine>

1.2 Shrnutí poznatků

Z výše uvedených příkladů v sekci 1.1 lze vypožorovat určité společné vlastnosti a zformulovat několik závěrů:

- o uživateli je vedena spousta záznamů, především historie jeho chování na stránkách
- velký důraz je kladen na zpětnou vazbu (vyjádření zájmu uživatele o doporučený obsah)
- stále je využíváno osvědčených přístupů kolaborativního filtrování a filtrování na základě obsahu
- síla není v použití jednoho konkrétního algoritmu, ale v kombinaci více metod a přístupů dohromady
- většina výpočtů běží na pozadí v tom samém čase, co uživatel tráví prohlížením stránek, a je schopna rychle se přizpůsobit okolnostem
- problematika má silnou závislost na strojovém učení a teorii pravděpodobnosti a statistiky (především bayesovské)

Existujících řešení je tedy celá řada. Každé z těchto řešení je přitom využíváno k vlastnímu účelu a není snadno přenositelné.

Navíc se zdá, že době, kdy obchodníkům stačilo na svůj elektronický obchod nasadit jednoduchý algoritmus kolaborativního filtrování, odzvonilo a budoucnost patří systémům schopným nějaké predikce a přizpůsobení svého vývoje, a to vše v reálném čase.

Analýza a návrh řešení

Tato kapitola je celá věnována analýze požadovaného chování systému.

Nejprve se budu zabývat požadavky, které vyplynuly z úvodních konzultací s vedoucím práce a též po vlastním zkoumání řešeného problému. Se znalostí těchto požadavků pak bude možné provést hrubý návrh architektury systému včetně technického řešení komponent, jimiž bude systém disponovat.

S ohledem na výstupy získané v této kapitole bude možné provést implementaci systému.

2.1 Požadavky

Za účelem vyšší přehlednosti jsem se nejprve rozhodl související požadavky strukturovat do zastřešujících skupin trojího typu (globální požadavky, rozhraní a systém). Nakonec se ukázalo, že mezi skupinami *rozhraní* a *systém* existuje tak tenká hranice (z hlediska požadovaného chování, nikoliv z hlediska implementačního), že jsem skupiny redukovány na dvě.

2.1.1 Globální požadavky na systém

- Systém bude klást důraz na zpětnou vazbu, podle které bude přizpůsobovat své chování.
- Systém bude zpětnou vazbu přijímat na principu odměny za dobré doporučení (přičítání v poměru) a trestu za špatné (odečítání v poměru).
- Systém bude v pravidelných intervalech ukládat do databáze svůj aktuální stav.
- Systém bude schopen v případě pádu aplikace a po jejím opětovném spuštění načíst naposledy uložený stav.
- Systém bude veškeré své operace týkající se doporučování provádět a vyhodnocovat v reálném čase (live read & live write).

- Systém bude schopen automaticky se přizpůsobovat vývoji v čase normalizováním ukládaných hodnoty (z důvodu ochrany proti přetečení datových typů).
- Systém bude na každou klientskou žádost vracet příslušnou odpověď (i chybovou) – neexistuje nic jako odpověď *null*.

2.1.2 Uživatel systému & systémové rozhraní

- Uživatel bude mít možnost vytvářet skrze systémové rozhraní kolekce se seznamem algoritmů určených pro kombinování a následnou predikci.
- Uživatel bude mít možnost zaslat systému žádost o radu a obdržet informaci, který algoritmus pro doporučení obsahu by měl v danou chvíli zvolit.
- Uživatel bude mít možnost zaslat systému informaci o tom, pro jaký algoritmus doporučení se rozhodl.
- Uživatel bude mít možnost zažádat o doporučení obsahu prostřednictvím algoritmu, jenž mu byl navržen systémem.
- Uživatel bude mít možnost zaslat systému informaci o zpětné vazbě týkající se algoritmu, jenž si pro doporučení zvolil.
- Aplikace bude umožňovat prostřednictvím svého rozhraní zpracovat informaci, že jeden uživatel dělá něco s jedním dokumentem (reakce na zpětnou vazbu).
- Aplikace bude umožňovat prostřednictvím svého rozhraní mazat či zneviditelnit data již neaktuální pro doporučování.

Dle disciplín softwarového inženýrství lze výčet uvedený výše označit za **funkční požadavky**.

Definuje nyní i tzv. **nefunkční požadavky**, které specifikují vlastnosti a omezující podmínky kladené na systém:

- Systém bude postaven na platformě Java.
- Pro uchování informací o uživateli, položkách a jejich vzájemné interakci bude využita platforma pro vyhledávání v textu Apache Solr.
- Systém bude umožňovat přístup aplikacím třetích stran prostřednictvím RESTful webových služeb (vychází ze zadání).
- Systém bude postaven tak, aby se dal snadno parametrizovat.
- Systém bude připraven na situaci, že jej bude využívat více uživatelů současně.
- Systém poběží jako samostatná aplikace na serveru naslouchající na TCP portu. Veškerá komunikace s ní bude probíhat formou zasílání zpráv a volání procedur.

- Pro snadné nasazení a testování systému na libovolné pracovní stanici bude nutné vytvořit Chef cookbook/recipe ²⁰.

2.2 Adaptibilní systém

Pro zdárnou implementaci systému splňujícího všechny požadavky vzešlé z analýzy výše je třeba důkladně zvážit, jaké komponenty bude tento systém obsahovat a případně jaké algoritmické postupy bude vhodné využít. Na základě zkoumání existujících implementací v kapitole 1 mě zaujal projekt *Open recommendation Platform* (zkr. ORP) společnosti **plista** ²¹ prezentovaný na posledním ročníku konference ACM RecSys 2013 v Hong Kongu.

Motivací ORP bylo dosáhnout lepších výsledků kombinací více metod doporučování obsahu společně se zapojením kontextu uživatele (informacemi čerpanými převážně z HTTP hlaviček). Takovými informacemi mohou být:

- IP adresa, která může prozradit geologickou lokaci uživatele
- denní doba, kdy uživatel přistupuje ke stránce
- user agent prohlížeče informující o zařízení, ze kterého bylo k obsahu přistoupeno (mobilní telefon, PC)
- referer pro zjištění způsobu přístupu (přístup z vyhledávání nebo přímý přístup)

Abstraktní pohled na ORP znázorňuje obrázek 2.1, na kterém je systém zachycen jako *Ensemble*. Ensemble je schopen dle uživatelských preferencí vybírat z kolekce doporučovacích algoritmů ten nejvhodnější, jenž pak použije k publikování obsahu pro daného uživatele. Konzumenti obsahu (*Visitors*) poté zasílají systému zpětnou vazbu, díky které dochází k rekalkulaci preferencí, což ovlivní výběr nejlepšího algoritmu pro další doporučení.

V prezentaci bylo zmíněno několik užitečných rad ohledně toho, co všechno by měl systém podobného typu umět. Zmíněna je potřeba rychlého webového serveru, na kterém bude aplikace běžet, dále nutnost rychlého síťového protokolu a rychlé fronty zpráv. Padla zde též potřeba rychlého úložiště pro data.


K dosažení správné funkcionality pro výběr nejlepšího algoritmu společnost používá tzv. *multi-armed bayesian bandit*, což je i jedna ze strategií, které mi na úvodní schůzce doporučil vedoucí této práce.

Se spoustou rad z této prezentace jsem se ztotožnil a vyhodnotil, že jejich naplněním by mohla být uspokojena velká část požadavků na systém stanovených výše.

Dalším studiem strategie *multi-armed bayesian bandit* jsem zjistil, že pro potřeby mé práce je natolik významná, že jsem se rozhodl věnovat jí samostatnou kapitolu 3.

²⁰<http://community.opscode.com/>

²¹<https://www.plista.com>



Obrázek 2.1: Abstraktní pohled na systém společnosti plista. Zdroj: [17]

2.3 Architektura systému

2.3.1 Server

Stěžejní serverovou komponentou je doporučovací platforma. Tu jsem pracovně nazval jako **Recommeng** (zkratka pro recommendation engine), abych o ní již nadále nemusel mluvit jako o *adaptibilním systému* či *systému pro kombinování metod*.


Diagram 2.2 znázorňuje abstraktní návrh architektury takové platformy. Mou snahou bylo zachytit přítomnost jednotlivých komponent systému, formu jejich vzájemné komunikace a též základní interakci uživatele se systémem.

V rámci ucelenosti zde uvádím přehled všech komponent nacházející se na serverové straně:

2.3.1.1 Aplikační server

Na aplikačním serveru poběží dvě aplikace.

Webová aplikace s rozhraním pro snadnou komunikaci s klienty. (viz diagram 2.2, komponenta *Web Application 1*) Aplikace bude mít na starosti obsluhu klientských požadavků na systém prováděných prostřednictvím protokolu HTTP. Zároveň bude disponovat sadou algoritmů, které lze použít pro doporučení obsahu. Dále bude aplikace obstarávat komunikační režii s druhou aplikací běžící na aplikačním serveru (*Web Application 2*), kterou je platforma pro vyhledávání v textu – Apache Solr.



Obrázek 2.2: Abstraktní návrh architektury a komponent adaptibilního systému, ve kterém je též vidět základní interakce uživatele se systémem.

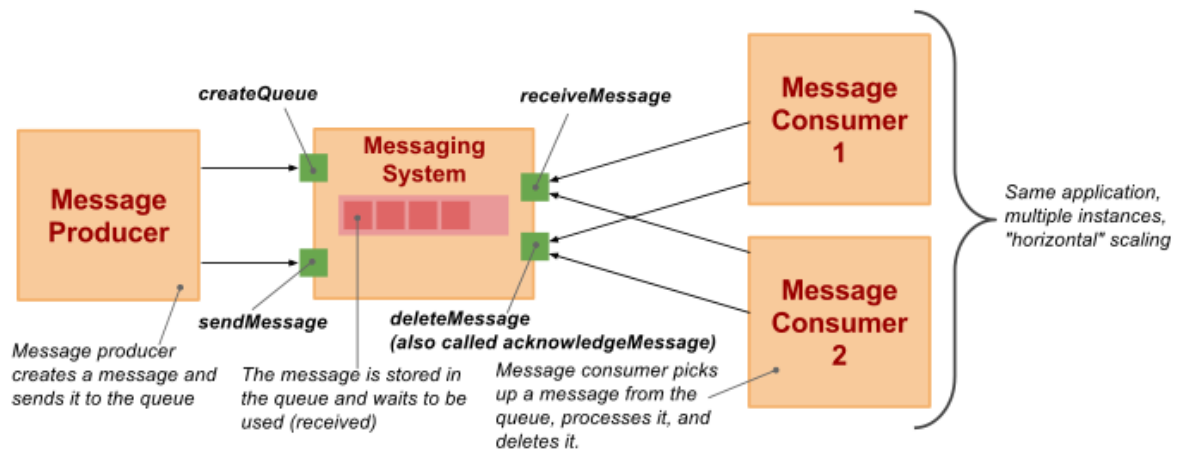
Apache Solr (viz diagram 2.2, komponenta *Web Application 2*) Přítomnost této aplikace vychází z nefunkčních požadavků. Apache Solr funguje jako samostatná komponenta umožňující fulltextové vyhledávání (details v kapitole 4).

2.3.1.2 Databáze

Kvůli potřebě ukládat průběžný stav aplikace (časové snímky) a snadného obnovení znalostí systému v případě přerušení běhu je nutné zapojit do návrhu Database Management System (DBMS).

Volba DBMS hraje důležitou roli i při škálování aplikací. V minulosti tolik používané standardní relační DBMS mohou způsobovat zpoždění při provádění čtení/zápisu a v některých případech hrát roli úzkého hrdla aplikace (bottleneck).

Ohledně tohoto problému by možná stálo za úvahu prozkoumat možnosti použití NoSQL databází, které jsou již ze svého principu navrženy pro spolupráci s aplikacemi zaměřenými na výkon a škálovatelnost.



Obrázek 2.3: Příklad MQ systému s producentem zpráv a konzumenty. Zdroj: [31]

2.3.1.3 Recomeng systém

Komunikaci s aplikací bude umožňovat systém pro zasílání zpráv (Messaging System) s využitím fronty zpráv (Message Queue). Toto řešení je zde nasnadě kvůli očekávání většího množství žádostí směřujících na systém a snadnější škálovatelnosti aplikace. Obecný příklad takového MQ systému znázorňuje obrázek 2.3

Producenti zpráv (klienti využívající aplikaci) vytvářejí zprávy, které jsou zasílány do fronty. Zprávy jsou z fronty postupně odebírány konzumenty, kteří mají jejich zpracování na starosti. Výhodou je časová nezávislost mezi producenty zpráv a konzumenty – producent tak může zasílat zprávy i tehdy, když žádný z producentů není k dispozici. Zprávy pak existují ve frontě, dokud se o jejich zpracování konzument nepřihlásí.

Recommeng systém bude taktéž komunikovat s databází, ale využívat ji pouze pro ukládání informací o stavu (což bude prováděno v pravidelných časových intervalech), respektive pro načítání posledního uloženého stavu při novém startu aplikace.

Důvodem pro vynechání komunikačního mezikroku s databází je požadavek na rychlost systému – veškerá data pro výpočet a predikci budou udržována přímo ve vnitřní paměti (uvnitř JVM).

2.3.2 Klient

Klientská strana není nikterak složitá. Potenciální uživatel aplikace má v zásadě dvě možnosti, jak s platformou komunikovat:

- jen a pouze zasíláním žádostí na REST API

- kombinací zasílání žádostí na REST API společně s přímou komunikací s Recommeng systémem prostřednictvím fronty zpráv

Některé ze systémových funkcionalit nelze bez komunikace s REST API využívat. Do této kategorie spadá například přidání nového vztahu k položce ve fulltextovém indexu nebo zaslání žádosti o doporučení obsahu některým z podporovaných algoritmů.

Přímé spojení s platformou skrze frontu zpráv bez nutnosti zapojení prostředníka v podobě REST API by ale měly umožňovat všechny možnosti použití Recommeng systému. Jmenovitě vytváření kolekcí se seznamem algoritmů, dále zasílání žádostí o radu pro výběr algoritmu a též metody informující systém o uživatelském chování jako zvolení konkrétního algoritmu nebo zaslání zpětné vazby o doporučení.

V diagramu 2.2 jsem se snažil zachytit různé formy komunikace klienta se systémem. Pro lepší názornost jsou jednotlivé žádosti barevně odlišeny. Ty lze považovat za modelové případy užití inspirované systémovými požadavky.

2.3.2.1 Červená varianta

Aneb klient přidávající nový vztah mezi položkou a jejím uživatelem do úložiště.

- klient zašle žádost na rozhraní
- aplikace (Web Application 1) za rozhraním se spojí s indexem
- v případě zdárného průběhu se přidá do indexu informace o tom, že 1 uživatel dělá něco s 1 dokumentem
- klient obdrží odpověď s výsledkem žádosti

2.3.2.2 Fialová varianta

Aneb klient zasílající platformě zpětnou vazbu ohledně doporučení, které dostal.

Fialová varianta může též představovat situaci, kdy klient žádá systém o radu, kterým algoritmem si má nechat doporučit obsah ve své budoucí žádosti o doporučení (viz žlutá varianta 2.3.2.3).

- klient zašle žádost na rozhraní
- aplikace (Web Application 1) za rozhraním se pokusí přistoupit k frontě zpráv
- pokud fronta existuje, žádost je přidána do fronty pro zpracování konzumentem (Recommeng systém)
- konzument zpracuje žádost a zasílá odpověď, kterou systém zpráv předá zpět do aplikace
- klient obdrží odpověď s výsledkem žádosti

2.3.2.3 Žlutá varianta

Aneb klient poptávající doporučení obsahu konkrétním algoritmem.

Toto doporučení klient poptává na základě odpovědi na žádost, která mu byla udělena systémem (viz fialová varianta 2.3.2.2)).

- klient zašle žádost na rozhraní
- aplikace (Web Application 1) za rozhraním zvolí vybraný algoritmus pro doporučení
- algoritmus přistoupí k datům v indexu, nad kterými se provede doporučení
- klient obdrží odpověď s výsledkem žádosti

2.3.2.4 Modrá varianta

Aneb klient, který se rozhodl nevyužít možnosti komunikovat prostřednictvím REST API. Svou žádost zasílá přímo do fronty zpráv.

- klient zašle žádost do fronty
- pokud fronta existuje, žádost je přidána do fronty pro zpracování konzumentem (aplikace Recommeng)
- konzument zpracuje žádost a zasílá klientovi odpověď


2.3.3 Komunikace

Výše jsme měli možnost poznat dva způsoby komunikace uživatele s doporučovací platformou. Dalším úkolem je navrhnout formát, jakým si budou vyměňovat producent s konzumentem data prostřednictvím volání vzdálených procedur Recommeng systému.

Vzhledem k obecné známosti protokolu HTTP jsem se rozhodl napodobit jeho chování a zachovat sémantiku:

- metoda (method)
- cesta (path)
- tělo zprávy (body)

Podobně jako v HTTP, i v případě mnou navrhované komunikace bude na každou žádost ve tvaru *method*, *path* a *body* přicházet odpověď ve tvaru *status* a *body* s využitím různých návratových kódů pro stav (status).



Obrázek 2.4: Ukázka REST endpointů navrhovaného adaptibilního systému

2.4 Rozhraní

Platforma poskytuje API pro interakci se systémem a daty formou RESTful (HTTP implementace REST 4.1.1). Každý uživatel tak může interagovat s rozhraním prostřednictvím zveřejněných endpointů.

Z prováděné analýzy vyplynuly požadavky na aplikační rozhraní takové, že je lze rozdělit do tří skupin dle podstaty úkolu, který mají plnit. K dispozici je diagram 2.4, který by měl celou věc osvětlit.

2.4.1 Rozhraní pro Recommeng

Komunikace s rozhraním by měla umožňovat vytvářet v Recommeng aplikaci kolekce s identifikátory algoritmů, jenž budou zapojeny do kombinování a predikce.

K tomu účelu bude sloužit endpoint:

```
/recommeng/ensemble/collection
```

Pokud uživatel zašle metodou POST žádost na tento endpoint (obsahující identifikátor kolekce a seznam algoritmů), v případě dosavadní neexistence v systému bude kolekce vytvořena a připravena k predikci.

Dále by měla existovat možnost zaslat na kolekci prosbu o predikci nejlepšího jejího algoritmu pro doporučení.

2. ANALÝZA A NÁVRH ŘEŠENÍ

`/recommeng/ensemble/collection/{collection-id}`

Toho dosáhneme žádostí s metodou GET, uvedením identifikátoru kolekce a případným specifikováním požadovaného výstupu (zda chceme vrátit jen nejlepší možnost či všechny možnosti seřazené sestupně od nejlepšího) v parametru dotazu.

Kvůli učení a vývoji znalostí systému je nezbytně nutné mít možnost zaslat informaci o výběru konkrétního algoritmu a též zpětnou vazbu vyjadřující, jak byl žádající uživatel s navrhovanou variantou spokojen.

`/recommeng/ensemble/collection/{collection-id}/{algorithm-id}`

Na endpoint výše v takovém případě zašleme metodou PUT upřesňující informaci o operaci, kterou chceme systému sdělit (výběr vs. zpětná vazba).

2.4.2 Rozhraní pro sadu základních algoritmů

Bude se jednat o jednoduchý endpoint, který si při žádosti vystačí s metodou GET.

`/recommeng/algorithms/{core-id}/{algorithm-id}`

Úkolem je zpracovat žádost uživatele o doporučení algoritmem, jehož identifikátor je uveden v cestě. Hledání doporučení bude provedeno nad dokumenty ze specifikovaného indexu (identifikátor indexu je též nutno uvést). V parametrech dotazu lze specifikovat další vstupy pro doporučení jako limit vrácených výsledků, identifikátor pro doporučení článků z té samé skupiny a další.

2.4.3 Rozhraní pro úložiště dat

Důležité rozhraní umožňující zaznamenat chování uživatele vzhledem ke sledovaným položkám.

`/recommeng/cores/{core-id}/document`

Prostřednictvím metody POST budou zasílány veškeré informace o položce (u článku např. identifikátor, text, skupina, datum publikace) a jejím uživateli (identifikátor), která má být uložena do fulltextového indexu. Druhou podporovanou metodou je metoda DELETE pro vyřazení položky z doporučování. Metoda je použita v žádosti na též endpoint jako metoda POST, pouze je nutné v parametru dotazu specifikovat identifikátor článku (z toho důvodu, že identifikátorem článku může být cokoliv, například URL adresa).

2.5 Sada algoritmů

Identifikace základní sady algoritmů určených pro kombinování je jeden z požadavků na systém plynoucí přímo ze zadání.

Uživatel žádající o radu pro výběr nejlepšího algoritmu obdrží od systému identifikátor reprezentující tento algoritmus.

Algoritmy pro doporučování vyhodnocují především informace o uživateli, položkách a hodnocení. Ukládány jsou ale i další údaje, například datum zveřejnění položky či její popis (u článku se může jednat o text zprávy). Také s těmito informacemi mohou doporučovací algoritmy pracovat.

2.5.1 Algoritmus náhodného výběru

Jak je patrné již z názvu, tento algoritmus vybírá položky pro doporučení naprosto náhodným způsobem. Jeho hlavním úkolem je být zde pro srovnání s ostatními algoritmy.

2.5.2 Algoritmus výběru dle nejnovějších položek

Doporučování dle nejnovějších položek je dalším z algoritmů s naivním přístupem k problému. Položky budou v tomto případě doporučovány sestupně dle zveřejněného data.

2.5.3 Algoritmus výběru nejlépe hodnocených položek

Jedná se o první algoritmus založený na složitějším výpočtu. Položky vzešlé z doporučení budou dle určitých parametrů nějakým způsobem lepší než ostatní, které se v doporučení neobjevily. Takovým parametrem může být například hodnocení na škále od 1 do 5, počet pozitivních hodnocení, souhrnné číslo udávající počet přečtení článku nebo jiný z mnoha způsobů vyjádření zájmu o položku.

2.5.4 Algoritmus výběru dle podobnosti obsahu

Algoritmus se snaží na základě podobnosti obsahu nalézt pro položku několik jí podobných položek z databáze. Podobnost se určuje porovnáním jednotlivých parametrů, například tagů, nadpisů nebo celého textu článku.

2.5.5 Algoritmus kolaborativního filtrování

Algoritmus je založen na modelu dřívějšího chování uživatele v systému. Model je většinou konstruován z chování většího množství uživatelů s podobným vkusem. V podstatě lze říci, že doporučení jsou založena na automatické spolupráci více uživatelů a výběru těch, kteří mají co nejpodobnější preference či chování.

Rozlišují se dva hlavní způsoby filtrování.

2.5.5.1 User-based

“You may like it because your friends liked it.” [21]

Aneb filtrování založené na uživatelích. Jedná se o starší variantu kolaborativního filtrování. Podstatou je vzít na základě určité podobnosti skupinu uživatelů (zdroj [21] udává cca 20 až 50) s podobným vkusem jako má uživatel, pro něhož je doporučení konstruováno, a poté předpovědět, jak moc zajímavá by pro uživatele byla pro něj dosud neznámá položka, se kterou jsou spojení uživatelé se stejným vkusem.

2.5.5.2 Item-based

“You tend to like that item because you have liked those items.” [21]

Aneb filtrování založené na položkách, které použila v roce 2001 jako první společnost Amazon. Myšlenka je taková, že uživatel, který si v minulosti zakoupil nějakou položku, bude v budoucnu při dalším nákupu vyhledávat položku podobnou. Například předpověď toho, co si uživatel zakoupí v budoucnu, lze uskutečnit analýzou historie nákupů uživatele [14].

Adaptibilní systém

3.1 Minimální teoretický základ

Ještě předtím, než se pustím do popisu strategie použité v implementaci systému, zopakuji zde některé pojmy týkající se strojového učení, teorie pravděpodobnosti a statistiky. Jedná se o minimální základ potřebný k pochopení postupů popisovaných dále v této sekci.

3.1.1 Strojové učení

Strojové učení je vědecká disciplína (jedna z větví oboru umělé inteligence), jež se zabývá tím, jak se má počítač přizpůsobit určité situaci, aniž by byl pro danou situaci explicitně naprogramován. Detailněji v sekci 3.2.

3.1.2 Agent

Agent je speciální autonomní program, který jedná samostatně a nezávisle bez vedení uživatele. Jeho úkolem je komunikovat s okolím a interagovat v závislosti na okolních podnětech. Dalšími důležitými vlastnostmi jsou schopnost příhodně reagovat na danou situaci a též proaktivně vykonávat činnost a dosahovat cíle prostřednictvím vlastní iniciativy. Jedná se o definici obecnou, ale pro naše potřeby zcela dostačující.

Problematika agentů a agentních systémů je jinak samostatný obor spadající do oblasti umělé inteligence a jeho zkoumání by vydalo na další závěrečnou práci.

3.1.3 Zpětná vazba

Zpětnou vazbou je označován proces, ve kterém na základě obdržených informací (například při komunikaci s nějakým systémem) a reakcí na ně ovlivňujeme jejich budoucí podobu – část systémového výstupu lze tedy použít jako vstup pro další činnost systému.

Rozlišujeme dva typy reakcí, a to kladnou zpětnou vazbu a zápornou zpětnou vazbu. Téma má blízko k psychologickému zkoumání toho, jakým způsobem dokáže ovlivnit zapojení odměny a trestu lidské chování.

3.1.4 Základy teorie pravděpodobnosti

Nejprve uvedu několik pojmů z teorie pravděpodobnosti, se kterými budu v následujícím textu pracovat.

Pravděpodobnostní prostor prováděného náhodného pokusu je tvořen trojicí (Ω, \mathcal{F}, P) , kde:

- Ω je prostor elementárních jevů (např. čísla od jedné do šesti na šestistranné hrací kostce), kde elementárním jevem nazýváme libovolný možný výsledek $\omega \in \Omega$
- \mathcal{F} je množina náhodných jevů (potenční množina ²² množiny Ω)
- P je přiřazení pravděpodobnosti jednotlivým jevům z Ω ($P(\Omega) = 1$)

3.1.4.1 Náhodný jev

Náhodný jev A výsledek náhodného pokusu. Příkladem jevu může být například hod mincí a pozorování, zda padla panna nebo orel. V tomto jevovém prostoru jsou zahrnuty celkem dva elementární jevy (hodnota panna a hodnota orel), které souvisejí s pokusem (pozorování výskytu elementárních jevů během házení).

3.1.4.2 Náhodná veličina

[16] Jak vidno, výsledkem náhodného pokusu nemusí být číslo (v příkladu výše jsme měli dvě hodnoty po stranách mince), proto je vhodné těmto výsledkům kvůli matematickému zpracování čísla přiřazovat. Způsob přiřazení čísla výsledku náhodného pokusu se označuje jako *náhodná veličina* X . Pro počítání padlých panen při opakovaném házení mincí by mohlo přiřazení vypadat například takto:

- $X(\text{panna}) = 1$
- $X(\text{orel}) = 0$

Náhodná veličina na pravděpodobnostním prostoru (Ω, \mathcal{F}, P) je tedy funkce $X : \Omega \rightarrow R$, která každému $\omega \in \Omega$ přiřadí $X(\omega)$ a pro kterou platí podmínka měřitelnosti:

$$\{X \leq x\} = \{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F}, \forall x \in R$$

²²Potenční množina množiny X je množina obsahující všechny podmnožiny množiny X

Dle typu se rozlišují náhodné veličiny diskrétní a spojité. Diskrétní náhodné veličiny mohou nabývat pouze konečného počtu hodnot z R (například ročník studia), zatímco spojité náhodné veličiny nabývají v určitém intervalu libovolné reálné hodnoty (například čas potřebný k dokončení diplomové práce).

Pravděpodobnostní rozdělení náhodné veličiny určuje její distribuční funkce.

3.1.5 Distribuční funkce

Distribuční funkce náhodné veličiny X je funkce $F : R \rightarrow \langle 0, 1 \rangle$ definovaná vztahem

$$F(x) = P(X \leq x) = P(\{\omega \in \Omega : X(\omega) \leq x\}).$$

Vyjadřuje tedy pravděpodobnost, že hodnota náhodné veličiny X nabude hodnoty menší nebo rovné zadané hodnotě (libovolnému $x \in R$). Distribuční funkce určuje rozdělení pravděpodobnosti.

3.1.6 Kvantilová funkce

[5] Podobně jako distribuční funkce, i kvantilová funkce se týká rozdělení pravděpodobnosti. Lze ji považovat za funkci inverzní k distribuční funkci, neboť zatímco distribuční funkce $y = F(x)$ vyjadřuje pravděpodobnost, s jakou bude hodnota náhodné veličiny X menší nebo rovna $x \in R$, výsledkem kvantilové funkce $x = F(y)^{-1}$ je hodnota x , pro kterou je výsledek náhodného pokusu se zadanou pravděpodobností y menší nebo roven x . Jinými slovy hledáme taková x , kterým odpovídá určitá hodnota distribuční funkce $F(x)$. Hodnoty této funkce jsou tedy *kvantily*.

3.1.7 Rozdělení pravděpodobnosti

Někdy se též označuje jako distribuce pravděpodobnosti náhodné veličiny X . Rozdělení pravděpodobnosti každému jevu popsánému veličinou X přiřazuje určitou pravděpodobnost. V diskrétním případě přiřazujeme pravděpodobnosti jednotlivým hodnotám (lze si představit jako samostatné body v grafu), ve spojitém případě pak intervalu hodnot náhodné veličiny.

Rozdělení pravděpodobnosti je celá řada, z diskrétních je známé například *binomické* (n pokusů s rovnocennou pravděpodobností) či *geometrické* rozdělení. Ze spojitých například *normální rozdělení*, *exponenciální rozdělení* nebo *beta rozdělení*.

3.1.8 Beta rozdělení

Beta rozdělení $Beta(\alpha, \beta)$ je spojité pravděpodobnostní rozdělení definované na intervalu $\langle 0, 1 \rangle$. Rozdělení má dva vstupní parametry α a β určující tvar.

Rozdělení se používá k modelování chování náhodných veličin, které jsou omezené na konečné intervaly.

3.1.9 Bayesovská statistika

Jedná se o moderní větev statistiky pracující s podmíněnou pravděpodobností. Základem bayesovské statistiky je známý *Bayesův teorém* (často označovaný jako Bayesova věta) vyjadřující pravděpodobnost hypotézy (H_j) v závislosti na datech (D) a případně modelu (M). Lze pomocí ni stanovit pravděpodobnost, aniž bychom měli k dispozici známá fakta z minulosti. Oproti klasické statistice taktéž netestujeme hypotézy, ale provádíme *odhady*.

3.1.9.1 Apriorní pravděpodobnost (prior)

Pravděpodobnost $P(H_j|M)$, označována jako *prior*. Značí to, co víme nebo si myslíme předem, ještě před získáním dat (např. výsledky předchozích experimentů) [37]. Lze jí vyjádřit určitou míru nejistoty, například podíl voličů, kteří budou v budoucích volbách hlasovat pro nějakého konkrétního politika.

3.1.9.2 Aposteriorní pravděpodobnost (posterior)

Pravděpodobnost $P(H_j|D, M)$, označována jako *posterior*. Udává výsledek celého snažení, tedy pravděpodobnost naší hypotézy v závislosti na předchozích znalostech (prior) a současně nových datech [37].

Díky uvedeným pravidlům je možné s každou další objevenou skutečností zpřesňovat pravděpodobnost výchozí hypotézy.

3.1.10 Náhodný výběr

Náhodného výběru se využívá k rozpoznání charakteru rozdělení (opakované pokusy dávají za stejných podmínek různé výsledky, které odpovídají hodnotám jednotlivých realizací náhodné veličiny). Jedná se o uspořádanou n -tici (X_1, X_2, \dots, X_n) náhodných veličin X_i , $1 \leq i \leq n$, které jsou nezávislé a mají stejné rozdělení pravděpodobnosti [9].

Zatímco **náhodným výběrem** označujeme n -prvkovou posloupnost nezávislých náhodných veličin X_1, X_2, \dots, X_n , pojmem **výběr** budeme značit n -prvkovou posloupnost reálných čísel x_1, x_2, \dots, x_n [33].

3.1.11 Statistická inference

[33] Uvažujme pojem *populace*, kdy populací myslíme náhodnou veličinu s jejím rozdělením pravděpodobnosti. Úkolem statistické inference je pak s použitím **výběru** z populace *odhadnout parametr*, neboli číselnou hodnotu platící pro celou populaci (tou může být například střední hodnota rozdělení, rozptyl a tak podobně).

Odhadem je myšleno získání číselné hodnoty nebo intervalu hodnot z výběru. Cílem je, aby měl takový odhad blízko skutečné hodnotě parametru.

Rozlišujeme dva typy odhadů, a to bodový, kdy odhadem je jedna hodnota, a intervalový, kdy je odhadem interval hodnot.

3.1.12 Multi-armed Bandits

Jeden z klasických učících problémů zasahující do teorie pravděpodobnosti. Herní strategie je podobná filosofii tradičního výherního automatu (představujícího *one-armed strategii*) s tím rozdílem, že multi-armed varianta má více herních pák, a proto lze v každém kole pro jednu hru volit mezi více automaty. Strategii se detailněji zabývá sekce 3.3.

S pojmy vysvětlenými výše souvisí strategie v tom smyslu, že použitím bayesovské varianty provádíme opakovaný výběr z konečného počtu rozdělení, čímž se snažíme maximalizovat průměrnou hodnotu.

Toho lze využít například k cílenému doporučování reklamy nebo výběru personalizované úvodní stránky pro uživatele vstupujícího na naše stránky. Což je vlastně analogie k problému řešenému v této práci.

3.2 Význam strojového učení při návrhu systému

Jak vyplynulo z rešerše 1 existujících řešení a provedené analýzy 2, vzhledem k povaze řešeného problému je nutné zaměřit se na metody *strojového učení*.

Těmito metodami lze dosáhnout generalizace vstupních instancí na správné výsledky nebo adaptovat existující systém na změny a reakce okolí.

Typickým příkladem je vytvořit z dostupných dat model, jenž například dokáže:

- predikovat cenu akcií za 6 měsíců (z aktuální výkonnosti společnosti a dostupných ekonomických dat)
- rozpoznat spam od regulérního e-mailu
- u pacienta hospitalizovaného s infarktem predikovat riziko dalšího infarktu
- napomoci společností zabývajících se internetovou reklamou v rozhodování se, kterou reklamní strategii použít k maximalizaci zisku

Algoritmy strojového učení dělíme do taxonomie (nadtříd a podtříd) založené na požadovaném výsledku nebo typu vstupu, jenž máme k dispozici během trénování stroje. Algoritmů je celá řada, zmíním zde alespoň ty nejtypičtější.

Supervised learning ²³ je typ učení, které se používá v případě, že máme k našim trénovacím instancím na vstupu korektní výsledky. Pomocí kombinace trénovacích vstupních instancí a jejich požadovaných výsledků lze systém adaptovat na situaci, že dokáže sám předpovídat výsledky pro každé další platné vstupní instance [36].

Využití nachází například v oblastech rozpoznávání řeči či detekci spamu.

Unsupervised learning ²⁴ je již ze samotné podstaty absence učitele obtížným problémem. Učení bez učitele se používá k analýze dat, když nemáme k dispozici informace od učitele (trénovací množinu). Pozorovaná data se mají vysvětlit pomocí matematických modelů.

Používá se v oblasti rozpoznávání vzorů [23].

Reinforcement learning ²⁵ je oblast informatiky týkající se chování agentů 3.1.2.

Jedná se o metodu, při které se agent učí, jakým způsobem má volit akce, aby našel optimální strategii pro dané prostředí.

Jedná se o učení bez učitele. Agent sice dostává odezvu, ale přímo z prostředí, takže musí experimentovat a zjišťovat, které stavy jsou nějakým způsobem dobré, a kterým stavům je lepší se vyhnout.

Průzkum probíhá na principu zpětné vazby v podobě odměny za akce dosahující cíle nebo trestu v opačném případě. Řeší se zde problém explorační vs. exploatační 3.3.2.

Rozlišujeme několik typů zpětnovazebního učení, například tzv. *single-stage* (agent se snaží uplatňovat zpětnou vazbu ihned po každé provedené akci), oproti kterému stojí typ *sekvenční* (agent uplatňuje zpětnou vazbu po obdržení série akcí). Dalšími typy jsou například *pasivní* a *aktivní* zpětnovazební učení přizpůsobující svůj vývoj na základě pevně dané strategie, respektive učení se a rozhodování o prováděných akcích za chodu systému [25].

Algoritmus zpětnovazebního učení začíná při svém spuštění ve stavu nevědomí, kdy neví nic o daných okolnostech a začíná nabývat své vědomosti postupným testováním systému. Postupující dobou běhu (a tím, jak vstřebává data a vyhodnocuje výsledky) se učí rozpoznat, jaké chování je nejlepší.

3.2.1 Zvolená strategie

Za nejvhodnější strategii, která by byla schopna plnit požadavky definované na tuto práci, jsem zvolil *algoritmus zpětnovazebního učení*.

O strategii lze též mluvit jako o *online učení*. Nutno zmínit, že slovem online zde není míněno něco ve smyslu internetu, ale ve smyslu neustále se vyvíjející aktualizace dat. Učící algoritmus v každém kole vykoná nějakou akci, přijme zpětnou vazbu a přičítá si daný zisk či ztrátu.

²³učení s učitelem

²⁴učení bez učitele

²⁵zpětnovazební učení nebo též učení posilováním

Z matematického hlediska má online učení propojení na klasické online algoritmy, teorii (opakovaných) her a teorii pravděpodobnosti.

Díky těmto znalostem tak můžeme navrhovat pravděpodobností dynamické systémy, kterými lze modelovat složitá průmyslová zařízení nebo třeba výherní automat známý jako *Multi-Armed Bandit*.

3.3 Multi-armed Bandits algoritmus

3.3.1 Princip algoritmu

[19] Základ algoritmu si lze představit tak, že hráč stojí před N výherními automaty (ty jsou podle dle strategie nazývány jako bandité) a v každém kole má možnost vybrat si jeden, na kterém bude hrát.

Strategie je formálně popsána jako skupina výnosových distribučních funkcí 3.1.5 $B = \{A_1, A_2, \dots, A_N\}$, kde N je počet banditů (každý z banditů má tedy přiřazenu právě jednu distribuční funkci vyjadřující pravděpodobnost úspěchu).

Hráč zpočátku nedisponuje žádnou informací o průběhu hry, ani o rozložení pravděpodobnosti úspěchu mezi bandity, a maximalizace výhry může dosáhnout pouze tím, že v každém kole vhodně vybere vždy jednoho z banditů.

Kdyby hráč věděl, u kterého z banditů je největší pravděpodobnost výhry, samozřejmě by vždy vybíral právě tohoto. Pravděpodobnosti výher u jednotlivých automatů jsou ale neznámé. Úkolem hráče tedy je nalézt nejlepšího banditu, a to tak rychle, jak jen to je možné, aby jej mohl co nejvíce využít 3.3.2.

3.3.1.1 Návrh strategie

Návrh strategie spočívá v tom, že systém jednotlivé bandity nejdříve testuje 3.1.11 za účelem získání znalostí nutných pro další vývoj. Jakmile nabude více znalostí, je možné zaměřit se na bandity, kteří poskytují díky užitečným znalostem největší odměnu.

Úkol je komplikován stochastickou povahou banditů. Suboptimální bandita může přinášet spoustu výher, což by nás mohlo přimět uvěřit, že právě tento bandita je tím nejlepším. Podobně ale uvažovat i naopak – nejlepší bandita totiž může zpočátku přinášet spoustu proher.

Na místě jsou dvě otázky:

- Měli bychom dávat stále šanci i banditům, u kterých často prohráváme, nebo na ně zanevřít a štěstí zkoušet u jiných?
- Pokud nalezneme banditu, který nám přináší *docela dobré* výsledky, měli bychom se s ním spokojit a nadále maximalizovat svou výhru pouze u něj? Nebo se vyplatí zkoušet i nadále další bandity v naději, že se povede nalézt ještě lepšího?

Tato dilemata jsou odborně nazývána jako *explorace* a *exploatace*.

3.3.2 Explorace vs. exploatace

Explorace Nacházení nových oblastí hledání, kdy agent nevyužívá předchozích znalostí (agent stále zkouší nové akce, jejichž výsledek nezná).

Exploatace Využívání stávajících znalostí. Hrozí uvážnutí v lokálních extrémech. (agent provádí akce, o kterých ví, že mu přinášejí užitek).

Optimální strategie nemůže být ani čistě explorační, ani čistě exploatační. Hledá se vyvážený kompromis.

3.4 Bayesian Bandits

Nalézt optimální řešení tedy nepatří k triviálním problémům. Systému může trvat léta, než se k němu dopracuje. Naštěstí existuje spousta *přibližně optimálních* řešení.

Jedním z řešení je algoritmus zvaný *Bayesian Bandits*. Algoritmus přímo souvisí s učením založeným na zpětné vazbě.

Bayesovské řešení začíná prior 3.1.9.1 stanovením pravděpodobností výhry pro každého banditu. Hodnoty jsou v rozmezí $\langle 0, 1 \rangle$. Jak již bylo řečeno, každého banditu reprezentuje jedna distribuční funkce.

V každém kole, kterých je v případě mnou vytvářeného systému nekonečně (neboť kola jsou závislá na žádostech uživatelů, kteří přistupují k systému – standardní použití Multi-armed Bandits pracuje s konečným počtem stavů), probíhá následující proces:

1. pro každého z N banditů proved' prior 3.1.9.1 (počty pokusů, výher, ...) výběr z náhodné veličiny X_b 3.1.4.2 bandity b
2. ze získaných dat vyber 3.1.10 banditu s největší hodnotou předchozího výběru, například $B = \operatorname{argmax} X_b$
3. pozoruj výsledek vrácený banditou B a proved' prior aktualizaci tohoto bandity.
4. vrať se na krok 1

Počáteční prior pravděpodobnost je u každého bandity Beta rozdělení 3.1.8 $Beta(\alpha = 1, \beta = 1)$ (uniformní rozdělení).

Pozorovaná náhodná veličina X (výhra či prohra, tedy 1 nebo 0) je binomická. Posterior 3.1.9.2 pravděpodobnost se po provedení pokusu přizpůsobuje novému rozdělení:

$$Beta(\alpha = 1 + X, \beta = 1 + 1 - X).$$

V případě jakéhokoliv úspěchu se provádí navýšení pravděpodobnosti, se kterou bude algoritmus znovu vybrán. V případě neúspěchu se tato pravděpodobnost exponenciálně snižuje. V každé další hře se již systém rozhoduje s touto pravděpodobností (mezi explorací a exploatací).

Pokud tedy chceme odpovědět na dřívější otázku, zda bychom měli dávat stále šanci i banditům, u kterých často prohráváme, nebo na ně zanevřít a zkoušet štěstí u jiných, tento algoritmus nám navrhuje to, abychom prohrávající bandity přímo nevyřazovali, ale vybírali je stále méně často, jakmile získáme dostatek jistoty, že existují i lepší bandité.

Existuje tu nenulová šance, že prohrávající bandita dosáhne statusu B , pravděpodobnost této šance se ale snižuje s rostoucím počtem odehraných kol.


Obrázek 3.1 znázorňuje postup pro problém tří banditů ($N = 3$), jakým se algoritmus učí s rostoucím počtem her. Přerušované čáry pod grafy hustoty každého rozdělení reprezentují skryté reálné pravděpodobnosti (v obrázku mají hodnoty 0.85, 0.60, 0.75). Z uvedeného příkladu vyplývá, že o skryté pravděpodobnosti se až tolik nestaráme. Daleko větší význam pro nás má výběr nejlepšího bandity, což je vidět na distribuci červeného bandity. Ta je velice široká, což představuje skutečnou neznalost o tom, jak velkou skrytou pravděpodobností bandita disponuje. O pravděpodobnosti tedy nemáme nejmenší tušení, jsme si ale docela jistí tím, že bandita není nejlepší. Algoritmus se proto rozhodne ignorovat jej.

3.4.0.1 Stanovení míry učení

Vzhledem k tomu, že prostředí se rychle mění v čase, je nutné stanovit míru učení. Technicky vzato je standardní Bayesian Bandits algoritmus schopen učit se sám pomocí aktualizovaných parametrů vstupujících do $Beta$ rozdělení po každé hře. Stanovením vhodné míry učení lze docílit toho, že algoritmus se bude přizpůsobovat měnícímu se prostředí rychleji.

Pokud stanovíme míru $\ll 1$, algoritmus bude předchozí výsledky zapomínat rychleji a častěji bude zkoumat nové možnosti. Míra $\gg 1$ implikuje naopak to, že algoritmus bude sázet na časnější dřívější výhry, čímž ale riskuje to, že se nedokáže rychle adaptovat na náhlé změny (je více imunní vůči rychle se měnícímu prostředí).

3. ADAPTIBILNÍ SYSTÉM



Obrázek 3.1: Vizualizace sekvenčního učení řešení od jedné do tisíce her. Zdroj: [19]

Realizace

Následující kapitola se zaměřuje na popis programátorských principů, které jsem následoval při práci na realizaci systému, stejně tak popisuje technologie použité při implementaci a vzniklé výsledné řešení.

4.1 Principy a technologie

4.1.1 RESTful API

4.1.1.1 REST

REpresentational State Transfer (REST) je architektonický styl definující určitá pravidla a vlastnosti návrhu API webových služeb orientovaných na zdroje. REST je silně založen na architektuře Klient-Server (server poskytuje přístup ke zdrojům, klient k nim může přistupovat a modifikovat je) a k jeho realizaci je možné využít protokolu HTTP (takovou realizaci pak nazýváme jako RESTful). Role tohoto protokolu zde není nikterak náhodná, neboť autorem REST není nikdo jiný než Roy Fielding, jenž je u protokolu HTTP podepsaný jako spoluautor [22].

Díky protokolu HTTP lze následovat mnoho pravidel návrhu RESTful API, například přítomnost adresovatelných zdrojů, kdy je každý zdroj adresovatelný pomocí Uniform Resource Identifier (URI). RESTful pro manipulaci se svými zdroji používá též HTTP metody (GET, POST, PUT, DELETE, ale i další, například OPTIONS či PATCH). Další vlastností je užívání standardních stavových kódů ²⁶ HTTP (typicky 2xx, 3xx, 4xx, 5xx) v odpovědi na žádost či bezstavová komunikace.

Data mohou být reprezentována v rozličných formátech jako XML, JSON či YAML.

²⁶Definici všech stavových kódů viz <http://www.w3.org/Protocols/rfc2616/rfc2616-sec10.html>.

Padla zde zmínka o bezestavosti. V případě REST k vyjádření přechodů mezi stavy aplikace používáme odkazy. Tento princip je nazýván jako *Hyper-text as the Engine of Application State* (HATEOAS).

4.1.1.2 Jersey (JAX-RS)

Java API for RESTful Web Services (JAX-RS) ²⁷ je standard definovaný v Java Specification Request 311 ²⁸. Jedná se o specifikaci pro RESTful webové služby implementované v programovacím jazyce Java.

Pomocí JAX-RS lze s využíváním anotací jednoduše a přehledně definovat sémantiku jednotlivých tříd a jejich metod z hlediska využití v architektuře REST. Příklady anotací jsou `@Path(relativní_cesta)` pro specifikaci relativní cesty zdroje, `@GET` či `@POST` specifikující typ žádosti nebo třeba `@QueryParam` pro přiřazení parametru HTTP dotazu k hodnotě parametru příslušné metody třídy.

Pro účely implementace rozhraní systému Recommeng jsem zvolil vzhledem k předchozím zkušenostem referenční implementaci tohoto standardu v podobě frameworku **Jersey 2.x**.

4.1.2 Fronta zpráv a síťová komunikace

4.1.2.1 ØMQ

ØMQ (ZeroMQ) ²⁹ je vysoce výkonná ³⁰ síťová knihovna napsaná v programovacím jazyce C++ vhodná k nasazení v distribuovaných a vícevláknových aplikacích, které vyžadují velkou škálovatelnost. S jejím využitím lze poměrně snadno navrhnout komplexní komunikační systém. Ke komunikaci užívá socketů ³¹. Duchovním otcem a spoluautorem knihovny je slovenský expert na oblast messaging middleware Martin Sústrik ³².

Hned na úvod je nutné sdělit, že se nejedná o klasický messaging system (message-oriented middleware) takového typu, jakým je například Apache ActiveMQ ³³ a jemu podobné systémy. Takové systémy jsou většinou hotová řešení připravená k okamžitému nasazení a integraci s dalšími službami.

Filosofie ZeroMQ je jiná, neboť jde především o multiplatformní knihovnu určenou k programovému využití (nabízí podporu více než 30 programovacích jazyků ³⁴). Pomocí jednoduchého socketového API umožňuje programátorovi sestavit si vlastní messaging system dle svého nejlepšího uvážení. Programátor

²⁷<https://jax-rs-spec.java.net>

²⁸<https://jcp.org/en/jsr/detail?id=311>

²⁹<http://zeromq.org>

³⁰Viz výkonnostní testy na oficiální stránce http://zeromq.org/results:_start.

³¹Socket je mechanismus, kterým je možno zprostředkovat lokální či vzdálenou komunikaci dvou uzlů, která má charakter klient/server [32].

³²<http://250bpm.com/contact>

³³<http://activemq.apache.org>

³⁴TODO

využívá ze strany API veškerou podporu usnadňující práci se sítí a s trochou nadsázky lze prohlásit, že se stará pouze o zasílání zpráv. Sama socketová komunikace je výrazně zjednodušena.

Knihovna nám navíc dává kompletní svobodu v tom, jakým způsobem zakódujeme naši zprávu (JSON, BSON nebo jakýkoliv vlastní navržený formát).

Podporovány jsou čtyři protokoly pro komunikaci [20]:

tcp jako model síťově založeného přenosu (procesy na jedné síti)

inproc jako model komunikace vláken uvnitř jednoho procesu

ipc jako model komunikace mezi procesy (procesy out-of-box)

multicast komunikující skrze PGM ³⁵.

Knihovna také definuje základní vzory zasílání zpráv, ať už se jedná o doručování zpráv na jednotlivé uzly, mapování uzlů na vlákna, procesy či umisťování zpráv do fronty ³⁶. Každý vzor zároveň určuje jinou síťovou topologii.

Základními vzory jsou:

- Request-reply
- Pub-sub
- Pipeline
- Exclusive pair

Nejvhodnějším vzorem pro mou práci je díky nátuře navrhovaného systému (zasílání zpráv a odpovědi na ně) vzor Request-reply, jehož konkrétní použití následuje záhy v sekci Popis realizace adaptibilního systému. Ostatní vzory nemá smysl v rámci této práce popisovat.

Pro účely Recommeng systému jsem se rozhodl využít čistou Java implementaci knihovny ZeroMQ v podobě knihovny **jeroMQ** ³⁷. Z výkonnostního hlediska za původním řešením zaostává jen nepatrně ³⁸ a navíc je mnohem jednodušší integrovat ji do vyvíjené aplikace prostým přidáním knihovny do projektu.

4.1.3 Úložiště dat

4.1.3.1 Apache Solr

Apache Solr ³⁹ je populární ⁴⁰ open-source platforma pro vyhledávání napsaná v programovacím jazyce Java. Jejími charakteristickými vlastnostmi jsou

³⁵<http://tools.ietf.org/html/rfc3208>

³⁶<http://zguide.zeromq.org/page:all#Messaging-Patterns>

³⁷<https://github.com/zeromq/jeromq>

³⁸Viz srovnávací testy <https://github.com/zeromq/jeromq/wiki/Performance>.

³⁹<https://lucene.apache.org/solr>

⁴⁰Viz seznam serverů využívajících služeb Solr <https://wiki.apache.org/solr/PublicServers>

podpora pro fulltextové vyhledávání, fasetové vyhledávání (analogie ke konstrukci GROUP BY v RDBMS), dobrá škálovatelnost pomocí kešování a distribuovaného vyhledávání, využívání vyhledávací konstrukce *more like this*, o které bude řeč v sekci 4.4, a také například tzv. *near real-time indexing* ⁴¹ (dokumenty je možné vyhledávat téměř ihned po jejich zaindexování).

Z hlediska architektury programu jde o samostatný server pro fulltextové vyhledávání běžící v servletovém kontejneru (například Apache Tomcat). K indexaci a fulltextovému vyhledávání využívá ve svém jádru knihovnu Apache Lucene.

Apache Lucene ⁴² je vysoce výkonná knihovna pro účely vyhledávání v textu a indexování.

Vstupem pro indexaci jsou dokumenty. Každý takový dokument obsahuje množinu elementů, kde je tento element nazvaný jako *field*). Každý field má své jméno, datový typ a případně další atributy.

Vstupem pro vyhledávání jsou textové řetězce (viz syntax ⁴³, případně dotazované objekty.

Index je uložen na disku ve formě souborů ve struktuře invertovaného indexu dokumentů [34].

Ukázka definice několika field dokumentu ve schématu Solr:

```
<field name="userId" type="int" indexed="true" stored="true"
  multiValued="true"/>
<field name="time" type="date" indexed="true" stored="true"/>
<field name="usedInRec" type="boolean" indexed="true" stored="true"/>
>
```

Ukázka reprezentace dokumentu ve výsledku vyhledávání pomocí Apache Solr ve formátu XML:

```
<doc>
  <int name="id">1</int>
  <str name="articleId">http://somedomain.org/somearticle.html</str>
  >
  <str name="articleText">Hello Bob and Alice!</str>
  <int name="group">123</int>
  <bool name="usedInRecommendation">true</bool>
  <date name="time">2009-04-12T20:44:55Z</date>
  <float name="1_rating">0.1</float>
  <float name="2_rating">0.5</float>
  <float name="3_rating">0.5</float>
  <arr name="userId">
    <int>1</int>
    <int>2</int>
    <int>3</int>
  </arr>
  <long name="_version_">1465487644804775936</long>
```

⁴¹<https://cwiki.apache.org/confluence/display/solr/Near+Real+Time+Searching>

⁴²<http://lucene.apache.org/core>

⁴³http://lucene.apache.org/core/2_9_4/queryparsersyntax.html

</doc>

Formu jejich spolupráce lze popsat tak, že Apache Solr poskytuje pro vyhledávání RESTful API, za kterým je skryto a voláno JAVA API knihovny Lucene. Díky tomu je možné pomocí protokolu HTTP komunikovat s Apache Solr z jakékoliv platformy napsané v jakémkoliv programovacím jazyce.

K integraci Apache Solr s dalšími aplikacemi je možné vybírat ze spousty nástrojů a knihoven ⁴⁴. Pro účely mé aplikace psané v programovacím jazyce Java jsem zvolil knihovnu **SolrJ** ⁴⁵ s klientským rozhraním pro vyhledávání, přidávání a aktualizaci indexu.

4.1.3.2 Apache Cassandra 2.0

Apache Cassandra 2.0 ⁴⁶ je open-source distribuovaný DBMS navržený pro obsluhu velkého množství dat. Z hlediska datového modelu je Cassandra jakýmsi hybridem mezi key-value (pod 1 klíčem je uložena 1 hodnota) a column-oriented databázemi. V dokumentaci [18] se lze dočíst, že jde o row-oriented databázi.

Základem modelu je *column family* (analogie tabulky v RDBMS), jež je složena z řádků a sloupců. Každý řádek má unikátní identifikátor ve formě klíče – každý řádek obsahuje více sloupců. Sloupce mají jméno, hodnotu a časovou značku. Výhodou proti RDBMS přístupu je to, že rozdílné řádky ze stejné column family nemusí sdílet stejnou množinu sloupců – do jedné nebo více řádek lze v libovolný čas zapsat jakýkoliv sloupec.

Vzhledem k tomu, že jedním z vyzdvihovaných případů užití databáze je uchovávání časových snímků, rozhodl jsem se ji experimentálně zapojit do vytvářeného Recommeng systému. Ještě předtím jsem však detailněji zkoumal možnost použití jiné NoSQL databáze, a to **Redis**.

Redis je klasickou key-value databází uchovávající data primárně v paměti. Postupným vývojem se jeho funkcionalita propracovala k tomu, že pod jeden klíč je nyní možné uložit několik datových struktur (např. množiny a asociativní pole). Vzhledem k ukládání dat do paměti disponuje značnou rychlostí, navíc jej lze dle konfigurace nastavit tak, aby se obsah paměti průběžně ukládal na disk pro potřeby snadného obnovení dat v případě pádu aplikace.

Jeho zapojení do aplikace jsem zvažoval ve fázi zkoumání, jakým způsobem bude v adaptibilním systému řešen failover dat. Po následném návrhu datového modelu pro ukládání časových snímků stavu aplikace jsem však sáhl po použití Apache Cassandra jako po lepší z nabízených variant pro budoucí potřeby práce (rozsahové dotazy, vizualizace vývoje systému apod.).

Velkým benefitem je podpora Cassandra Query Language (CQL), dotazovacího jazyka umožňujícího vytvářet podobné konstrukty, jaké nabízí jazyk

⁴⁴<http://wiki.apache.org/solr/IntegratingSolr>

⁴⁵<http://wiki.apache.org/solr/Solrj>

⁴⁶<http://cassandra.apache.org>

SQL. CQL je nyní k dispozici ve verzi 3.1 a s pomocí **DataStax Java Driver 2.0** mohu snadno manipulovat s databází přímo ze své aplikace.

4.1.4 Ostatní použité technologie

4.1.4.1 Apache Mahout

Apache Mahout ⁴⁷ je knihovna napsaná v programovacím jazyce Java, jež poskytuje implementaci rozličných technik z oblasti strojového učení:

- **shlukování (clustering)** – položky nacházejících se v určitých třídách (například webové stránky či novinové články) jsou organizovány do skupin tak, že položky nacházející se v těchto skupinách jsou si vzájemně podobné
- **klasifikace (classification)** – učení se ze stávajících kategorizací a zařazování neklasifikovaných položek do nejvhodnější kategorie
- **doporučování (recommendation)**
- **často se vyskytující skupiny položek (frequent itemset mining)** – analýza položek v rámci nějaké skupiny (například nákupní košík) a identifikace, které položky se nejčastěji vyskytují pohromadě

Pro tyto techniky realizuje příslušné algoritmy jako například kolaborativní filtrování, k-means, náhodné lesy, skryté markovské modely a další. Některé algoritmy jsou připraveny pro běh v distribuovaném módu s využitím paradigmatu Map/Reduce, některé pak v lokálním módu (samotný Mahout je založen na Apache Hadoop, ale lze jej pohodlně využívat i bez něj) [29]. Mahout poskytuje též knihovny pro obecné matematické operace (zaměřené hlavně na oblast statistiky) a kolekce ⁴⁸.

Využít jej pro potřeby své práce jsem se rozhodl poté, co jsem na něj narazil v projektu Mendeley 1.1.4 během zkoumání existujících řešení doporučovacích systémů.

4.1.4.2 Spring Framework

Při tvorbě každého nového Java projektu od základu je dobré zamyslet se nad možností využít některý z mnoha frameworků a dalších užitečných nástrojů, s jejichž pomocí si lze do značné míry usnadnit proces vývoje. Díky dobrým zkušenostem z dřívějších projektů jsem zvolil open-source framework pro tvorbu moderních enterprise aplikací **Spring** ⁴⁹.

Jeho výhodami jsou snadná konfigurovatelnost, podpora dependency injection, rozšiřitelnost a také integrace s jinými frameworky. V mém případě

⁴⁷<https://mahout.apache.org>

⁴⁸<https://mahout.apache.org/users/basics/mahout-collections.html>

⁴⁹<http://projects.spring.io/spring-framework>

to byla integrace s frameworkem Jersey, kterou jsem využil při implementaci RESTful API.

4.1.4.3 Apache Tomcat

Apache Tomcat je známý open-source webový server a servletový kontejner. Jedná se o oficiální referenční implementaci technologií Java Servlet a Java Server Pages (JSP). Na serveru mohou běžet uživatelské servlety (programy napsané v Javě), které umí zpracovávat požadavky zasílané pomocí HTTP protokolu a tímž protokolom na ně odpovídat. Apache Tomcat zde slouží jako zásobník servletů starajících se o jejich spouštění, běh, ukončování a podobně.

4.1.4.4 Správa závislostí

Často slýchaným pojmem z úst mnoha vývojářů v programovacím jazyce Java je tzv. *classpath hell*. V podstatě jde o problémy spojené s načítáním programových tříd. V dnešní době existuje spousta nástrojů schopných tento problém efektivně řešit používáním správně projektové struktury, sestavovacích nástrojů a nástrojů pro správu závislostí. Jmenujme například Apache Ant společně s Apache Ivy, Gradle nebo třeba Apache Maven.

Apache Maven jsem použil při implementaci všech komponent aplikace.

4.2 Popis realizace adaptibilního systému

Adaptibilní systém je samostatná Java Application.

4.2.1 Zavedení systému

Recommeng aplikace se spouští voláním metody `main()` třídy **EnsembleApp**. V této metodě je následně volána metoda `loadConsoleApplication()` abstraktní rodičovské třídy **EnsembleAppBase**.

Metoda `loadConsoleApplication()` hraje roli zavaděče aplikace, neboť postupným voláním v sobě obsažených metod zavádí do provozu celý systém. Hlavní ovládací třídou aplikace je třída **ApplicationBean**, což je Spring bean typu singleton. Jejím prostřednictvím je zavedena vrstva pro obsluhu zpráv i komponenty pro komunikaci s datovým úložištěm. `ApplicationBean` je mozkiem systému a při zavádění aplikace je získána ze Spring aplikačního kontextu.

Ten je možné velice jednoduše konfigurovat pomocí anotací ve třídě **AppConfig**:

```
@Configuration
@EnableScheduling
@ComponentScan(basePackages = {
    "cz.cvut.bouchja1.ensemble.spring"
```

4. REALIZACE

```
})
@PropertySource("classpath:application.properties")
public class AppConfig {
    ...
}
```

Anotace `@EnableScheduling` a `@ComponentScan` využijeme pro pravidelné ukládání stavu aplikace 4.2.1.2, anotaci `@PropertySource` zase pro možnosti parametrizace systému 4.2.1.1.

4.2.1.1 Parametrizace

Pro účely experimentování se systémem a testování funkčnosti s různě navolenou konfigurací je nutné načítat konfiguraci z editovatelného *properties* souboru. K tomu jsem využil Spring bean **PropertySourcesPlaceholderConfigurer**.

Konfigurační vlastnosti jsou do souboru *application.properties* přidávány ve formátu:

```
#cassandra or jvm
storage=cassandra
#storage=jvm

ensemble.machine.rate=0.5
ensemble.feedback.possitive.best=1.0
```

Konkrétní načítání v programu je pak díky použití `PropertySourcesPlaceholderConfigurer` velice jednoduché:

```
this.rate = Double.parseDouble(env.getProperty("ensemble.machine.
    rate"));
this.possitiveFeedback = Double.parseDouble(env.getProperty("
    ensemble.feedback.possitive.best"));
```

4.2.1.2 Pravidelné ukládání časových snímků

Pravidelné ukládání časových snímků jsem realizoval démonem (*cron*). Četnost jeho spouštění je možné volit přes parametr 4.2.1.1 v konfiguračním souboru aplikace. K tomuto účelu jsem vytvořil třídu **ScheduledJob** s veřejnou metodou *run()*. Na metodu bylo též nutné aplikovat anotaci s parametrem `@Scheduled(cron = "${scheduling.job.cron}")`.

Po zavolání této metody dojde k persistenci aktuálního stavu aplikace (tedy všech běžících bayesovských strategií), který je v té době v paměti, do databáze. Za předpokladu, že je možností použití databáze v konfiguračním souboru nastavená.

4.2.2 Vrstva pro obsluhu zpráv

Následující text popisuje postup, jakým jsem realizoval vrstvu pro obsluhu zpráv pomocí síťové knihovny ZeroMQ.

Většinová funkcionální je řešena třídou `MultiThreadServer` (obsahující též vnitřní třídu **WorkerThread**) z balíčku projektu Ensemble:

```
cz.cvut.fit.bouchjal.ensemble.socket
```

Postup by se dal shrnout do tří kroků:

1. rozhodnutí o komunikačním protokolu
2. definice síťové infrastruktury
3. realizace vzoru pro zasílání zpráv REQ/REP

4.2.2.1 Rozhodnutí o komunikačním protokolu

V prvním kroku bylo nutné rozhodnout o tom, jakým způsobem bude probíhat přenos dat směrem k Recommeng systému a naopak. Ze čtyř protokolů, jimiž disponuje ZeroMQ, jsem pro přenos dat zvolil síťový protokol **TCP**, a to z toho důvodu, že dle návrhu architektury by měl adaptibilní systém naslouchat na serveru a uživatelé s ním mít možnost navazovat spojení zvenčí mimo server.

Mezi komunikujícími klienty a Recommeng aplikací na serveru jsou vytvářena jednotlivá spojení a data jsou z jednoho koncového bodu na druhý přenášena ve formě bajtů.

Díky ZeroMQ API stačí připravit kontext a socket a metodě `bind()` nastavit adresu serveru s příslušným portem. Sama metoda se pak postará o zbylou práci (vytvoření endpointu pro příjem jednotlivých spojení a navázání na socket).

```
ZMQ.Context context = ZMQ.context(IO_THREADS_COUNT);  
// Socket to talk to clients  
ZMQ.Socket clients = context.socket(ZMQ.ROUTER);  
clients.bind("tcp://" + host + ":" + port);
```

4.2.2.2 Definice síťové infrastruktury

Propojení jednotlivých síťových komponent vychází z nativní povahy architektury Klient-Server. Server zastává roli stabilnější komponenty v síti, bude tedy přijímat spojení (viz ukázka s metodou `bind()` výše). Zároveň jsem mezi server a připojující se klienty umístil prostředníka v podobě *fronty*, jehož úkolem je jak obsluha všech žádostí na server, tak i odpovědi zpět klientům.

```
ZMQQueue queue = new ZMQQueue(context, clients, workers);
```

V případě více připojených klientů ZeroMQ automaticky obstarává obsluhu všech příchozích žádostí.

4.2.2.3 Realizace vzoru pro zasílání zpráv REQ/REP

Pro zasílání zpráv jsem zvolil obousměrně komunikující vzor *Request Reply*. Toto paradigma je známé z většiny serverových typů⁵⁰. Klient používá vlastní socket typu **ZMQ.REQ** k inicializaci žádosti, kterou následně odesílá na server. Server též užívá vlastního socketu **ZMQ.REP** ke čtení příchozí žádosti, po které zasílá odpověď.

Problém je, že vzor Request-Reply toho v základní variantě mnoho neumožňuje, proto bylo nutné umožnit asynchronní komunikaci implementací rozšíření v podobě socketů **ROUTER** a **DEALER** (dříve nazývány jako XREP a XREQ).

Řešení spočívá ve vytvoření více vláken (*workers*), kdy každé vlákno disponuje jedním REP socketem. Za tímto účelem je nutné vytvořit socket typu DEALER, kterému přiřadíme komunikační protokol *inproc://*. Poté, co DEALER obdrží zprávu, přenesení ji na jeden z REP socketů. Přitom sleduje, které REP sockety jsou zaneprázdněny, a které mohou naopak zprávu přijmout. Jakmile tento vybraný REP socket zpracuje zprávu, předá ji zpět a DEALER tuto zprávu přepošle tak, jak ji obdržel od socketu.

```
// Socket to talk to workers
ZMQ.Socket workers = context.socket(ZMQ.DEALER);
workers.bind("inproc://workers");
```

Kvůli podpoře více TCP spojení utvářených vůči serveru je nutné předřadit před socket typu DEALER ještě další typ socketu, kterým je ROUTER (byl vidět již v ukázce 4.2.2.1).

ROUTER přiřazuje vnitřní identifikátor každému k němu se připojujícímu socketu, následně obdrženou zprávu předává dál i s připojenými metadaty (identifikátor socketu) a poté, co zprávu obdrží zpět, ihned ji předává správnému REQ socketu, kterého identifikuje opět díky identifikátoru uchovávaném v metadatech.

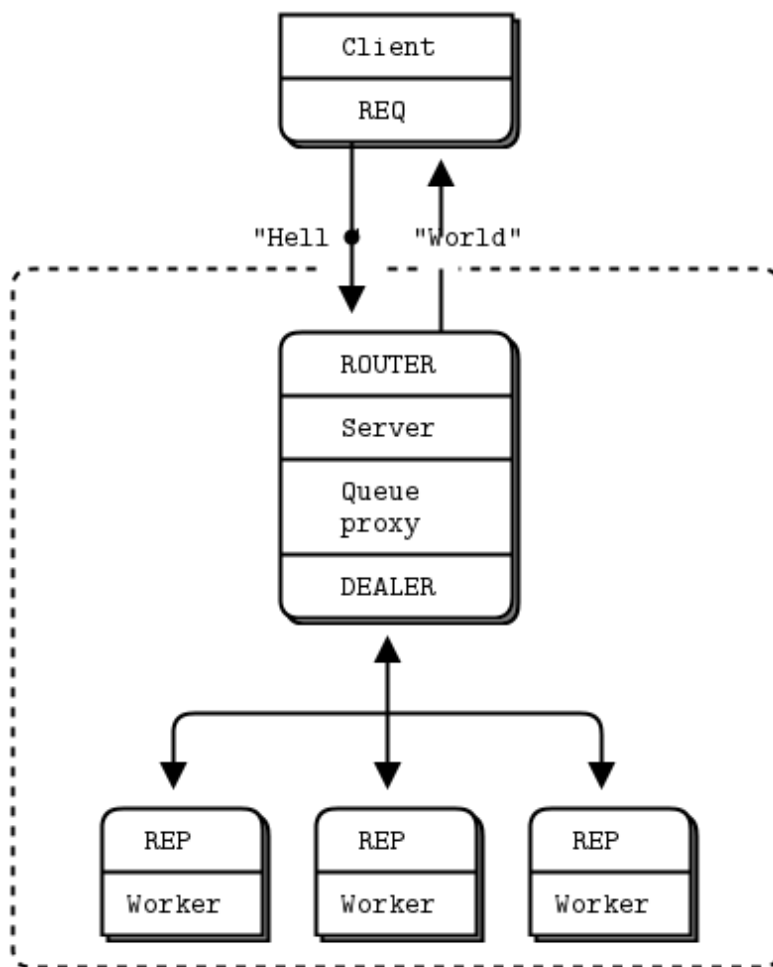
Toto chování je umožněno díky vestavěné funkcionalitě ZMQQueue (viz příklad 4.2.2.2). Všechny zprávy, které přijme ROUTER, jsou zaslány na DEALER a naopak. Model této komunikace ilustruje obrázek 4.1.

```
//Forwards messages from router to dealer and vice versa.
new Thread(queue).start();
```

Vyvoláním metody `start()` dojde k uzamknutí aktuálního vlákna (důvod, proč pro frontu existuje vlastní vlákno). To je jedna z pokročilých vlastností ZeroMQ – pro vývoj vícevláknových aplikací nejsou potřeba žádné mutexy, zámky, ani jakékoliv další formy komunikace kromě zpráv zasílaných napříč ZeroMQ sockety [13].

Na začátku procesu (při spuštění aplikace) je vytvořen ZeroMQ kontext (viz 4.2.2.1) a ten je předán všem vláknům, která jsou připravena pro komunikaci protokolem *inproc*:

⁵⁰HTTP, POP či IMAP



Obrázek 4.1: Vícevláknový server s využitím ROUTER a DEALER. Zdroj: [13]

4. REALIZACE

```
// Launch worker threads
for (int i = 0; i < threads.length; i++) {
    threads[i] = new MultiThreadServer.WorkerThread(
        i, context, api, new RequestHandlerJson()
    );
    threads[i].start();
}
```

Vláknům je parametrem předána instance třídy **RequestHandlerJson**, takže jsou schopny obsluhovat příchozí žádosti ve formátu JSON. Jedná se o implementaci rozhraní **RequestHandler** s jednou definovanou metodou pro obsluhu zpráv. Tento typ přijímají ve svém konstruktoru i pracovní vlákna. Řešení je tedy postaveno tak, aby bylo snadno rozšiřitelné pro jakýkoliv jiný formát komunikace, klidně vlastní.

```
public interface RequestHandler {
    public Operation handleMessage(byte[] message)
        throws MessageFormatException;
}
```

4.2.2.4 Technika zasílání zpráv a WorkerThread

O několik řádků výše bylo vysvětleno, jakým způsobem jsou na serveru zpracovány příchozí žádosti. Nyní již víme, že tuto funkcionalitu mají na starosti pracovní vlákna typu **WorkerThread**.

Každý *worker* v sobě udržuje kontext komunikace a pokud je na vstupu validní žádost, pro její zpracování je vyvolána příslušná operace rozhraní systému Recommeng. Sestavená odpověď je zaslána zpátky klientovi.

Třída **WorkerThread** je vláknová; kromě konstruktoru obsahuje pouze jednu metodu `run()`. Právě tato metoda má na svědomí veškerou obsluhu žádosti zahrnující zpracování zprávy, volbu správné operace na rozhraní systému a po zpracování pak zaslání odpovědi zpátky k žádajícímu klientovi.

V praxi to vypadá tak, že pokud je dané pracovní vlákno aktivní, čte příchozí žádost:

```
@Override
public void run() {
    ZMQ.Socket receiver = context.socket(ZMQ.REP);
    receiver.connect("inproc://workers");
    while (!Thread.currentThread().isInterrupted()) {
        byte[] request = receiver.recv(0);
        ...
    }
}
```

Po přečtení žádosti následuje zpracování:

```
try {
    Operation op = requestHandler.handleMessage(request);
    if (op.validateOperation()) {
        try {
            Reply reply = op.executeOperation(api);
            responseHandler.setReply(reply);
        }
    }
}
```

```
    } catch (Exception ex) {
        ex.printStackTrace();
    }
} else {
    responseHandler.createErrorReply(op.getErrorMessage());
}

try {
    int sleepTime = (threadNo % 2 == 0) ? 100 : 200;
    // Handle work, by sleeping for some time
    Thread.sleep(sleepTime);
} catch (InterruptedException e) {
    e.printStackTrace();
    Thread.currentThread().interrupt();
}
} catch (MessageFormatException | IOException ex) {
    responseHandler.createErrorReply(ex.getMessage());
}
```

Výsledkem zpracování zprávy je tedy operace realizována návrhovým vzorem **Command**. **Operation** je rozhraní deklarující metody pro validaci operace (`validateOperation()`) a její vykonání (`executeOperation()`). Každá třída implementující toto rozhraní je pak konkrétní operací, která volá rozhraní systému **Recommeng**.

Všechny typy podporovaných operací se nacházejí v aplikaci **Ensemble** v balíčku:

```
cz.cvut.fit.bouchja1.ensemble.operation
```

Jedná se o třídy splňující funkcionalitu dle funkčních požadavků 2.1:

- `OperationCreateBanditCollection`
- `OperationDetectBestBandit`
- `OperationDetectBestBandit`
- `OperationDetectBestBandit`

Výsledkem vykonání operace je vždy odpověď (třída **Reply** s atributy pro stavový kód a tělo zprávy), která je pomocí třídy **ResponseHandlerDefault** prezentována zpět klientovi.

4.2.3 Adaptibilní systém **Recommeng**

4.2.3.1 API

API systému **Recommeng** reprezentuje interface **EnsembleApiFacade**. Nejdůležitějšími metodami jsou metody:

- `createBanditSet(String banditSetId, Set<String> banditIds)`

- `detectBestBandit(String banditCollectionId, String filter)`
- `selectBandit(String banditCollectionId, String banditId)`
- `calculateFeedback(String banditCollectionId, String banditId, String feedbackValue)`

Tyto metody jsou volány prostřednictvím operací z vrstvy pro obsluhu zpráv 4.2.2. Metody jsou přímo napojeny na bayesovskou strategii, což je hlavní ovládací prvek Recommeng systému.

4.2.3.2 Bayesian Bandits

Strategii řeší tři třídy umístěné v balíčku:

```
cz.cvut.fit.bouchjal.ensemble.bandits
```

Bandit je třída reprezentující jednoho konkrétní banditu. Každý bandita má svůj identifikátor a atributy pro zaznamenávání výher a pokusů během jednotlivých her.

BanditsMachine je třída reprezentující jeden herní automat. Tento automat obsahuje seznam banditů a číselné parametry pro výpočty zpětné vazby a míry učení. V podstatě se jedná o konfiguraci, pomocí které je automat naprogramován. Tato konfigurace se nastavuje ve vnějším soubor (viz 4.2.1.1).

BayesianStrategy je třída reprezentující online učící strategii k řešení strategie Multi-Armed Bandit 3.1.12. Vzhledem k tomu, že je pro kombinování možné vytvářet více kolekcí s bandity, v systému může nezávisle na sobě fungovat více bayesovských strategií.

Každá z nich je pak reprezentována dle identifikátoru kolekce, každá má přiřazen svůj vlastní herní automat a logiku algoritmu.

Nejdůležitější metodou této třídy je metoda `sampleBandits(String banditCollectionId)` starající se jednak o výběr z prior pravděpodobností distribucí banditů nacházejících se v kolekci s identifikátorem *banditCollectionId*, a následně o volbu nejlepšího z banditů.

```
public Bandit sampleBandits(String banditCollectionId) {
    //sample from the bandits's priors, and select the largest
    sample
    for (int j = 0; j < banditsMachine.getBanditList().size();
        j++) {
        BetaDistribution beta = new BetaDistribution(1 +
            banditsMachine.getBanditAtIndex(j).getSuccesses(),
            1 + banditsMachine.getBanditAtIndex(j).getTrials()
            - banditsMachine.getBanditAtIndex(j).getSuccesses()
        );

        double inverseDistribution = beta.
            inverseCumulativeProbability(Math.random());
```



```
        roundInverseDistributions.add(inverseDistribution);
    }

    int banditIndexChoice = MathUtil.argmax(
        roundInverseDistributions);

    roundInverseDistributions.clear();

    return banditsMachine.getBanditAtIndex(banditIndexChoice);
}
```

4.3 Popis realizace RESTful API

RESTful API je realizováno jako Java Web Application.

4.4 Popis realizace sady algoritmů

Experimenty a vyhodnocení

Jednou z mnoha výzev pro někoho, kdo se snaží vybudovat doporučovací systém, je to, že je velice těžké dopředu říct, zda budou naše předpovědi dost přesné. Alespoň do té doby, dokud je nezačneme dělat a nebudeme pozorovat, jak často naši uživatelé přijímají naše návrhy. Je zde obrovský prostor možností (možných metod), z čeho vybírat.

key o testování

5.1 Testování různých způsobů chování

viz jak jarda vymyslel těch zhruba 5 příkladů, co mohou nastat

5.2 Experimenty

<http://contest.plista.com/wiki/example>

5.2.1 Vyhodnocovací technologie

Výpočty. kvůli kombinování budeme počítat s floaty

5.3 Zhodnocení aplikace

Slovní zhodnocení

5.4 Budoucí práce

bude li nějaká

Závěr

Literatura

- [1] BellKor, AT&T Labs, Inc. – Research. [online], stav ze dne 21.4.2012. Dostupné z: <http://www2.research.att.com/~volinsky/netflix/>
- [2] CNN Acquires Zite. [online], stav ze dne 21.4.2012. Dostupné z: <http://cnnpressroom.blogs.cnn.com/2011/08/30/cnnzite/>
- [3] easyrec: Recommendation Engine. [online], stav ze dne 24.4.2012. Dostupné z: <http://easyrec.org/recommendation-engine>
- [4] How does the Amazon Recommendation feature work? [online], stav ze dne 21.4.2012. Dostupné z: <http://stackoverflow.com/questions/2323768/how-does-the-amazon-recommendation-feature-work>
- [5] Kvantily. [online], stav ze dne 26.4.2012. Dostupné z: <http://www-troja.fjfi.cvut.cz/~limpouch/sigdat/pravdh/node8.html>
- [6] Mendeley: Recommendation Systems for Academic Literature. [online], stav ze dne 21.4.2012. Dostupné z: <http://www.slideshare.net/KrisJack/mendeley-recommendation-systems-for-academic-literature>
- [7] Netflix Contest: 1 Million Dollars for Better Recommendations. [online], stav ze dne 21.4.2012. Dostupné z: <http://www.uie.com/brainsparks/2006/10/02/netflix-contest-1-million-dollars-for-better-recommendations/>
- [8] Netflix offers streaming movies to subscribers. [online], stav ze dne 21.4.2012. Dostupné z: <http://arstechnica.com/uncategorized/2007/01/8627/>
- [9] Náhodný výběr. [online], stav ze dne 26.4.2012. Dostupné z: <ftp://math.feld.cvut.cz/pub/prucha/ubmi/predn/u12.pdf>

- [10] Proklik. [online], stav ze dne 21.4.2012. Dostupné z: <http://www.adaptic.cz/znalosti/slovnicek/proklik/>
- [11] What Is Affinity Analysis? [online], stav ze dne 21.4.2012. Dostupné z: <http://www.wisegeek.com/what-is-affinity-analysis.htm>
- [12] Zite is Flipping out. [online], stav ze dne 21.4.2012. Dostupné z: <http://blog.zite.com/2014/03/05/zite-is-flipping-out/>
- [13] ØMQ - The Guide. [online], stav ze dne 26.4.2012. Dostupné z: <http://zguide.zeromq.org/page:all>
- [14] Almazro, D.; Shahatah, G.; Albdulkarim, L.; aj.: A Survey Paper on Recommender Systems. [online], stav ze dne 26.4.2012. Dostupné z: <http://arxiv.org/pdf/1006.5278v4.pdf>
- [15] Anderson, C.: The Long Tail. [online], říjen 2004. Dostupné z: <http://archive.wired.com/wired/archive/12.10/tail.html>
- [16] Blažek, R. B.; Kotecký, R.; Hrabáková, J.; aj.: BI-PST – Pravděpodobnost a statistika, přednáška 3. [online], stav ze dne 26.4.2012. Dostupné z: https://edux.fit.cvut.cz/courses/BI-PST/_media/lectures/3_handout_pst-v2.pdf
- [17] Brodt, T.: Open Recommendation Platform. 2013, [Online; stav z 23. dubna 2014]. Dostupné z: <http://www.slideshare.net/d0nut/open-recommendation-platform>
- [18] DataStax: Architecture in brief | DataStax Cassandra 2.0 Documentation. [online], stav ze dne 27.4.2012. Dostupné z: http://www.datastax.com/documentation/cassandra/2.0/cassandra/architecture/architectureIntro_c.html
- [19] Davidson-Pilon, C.: The Multi-Armed Bandit Problem. [online], stav ze dne 27.4.2012. Dostupné z: <http://camdp.com/blogs/multi-armed-bandits>
- [20] Dennis, J.: ZeroMQ: Super Sockets. [online], stav ze dne 27.4.2012. Dostupné z: <http://www.slideshare.net/j2d2/zeromq-super-sockets-by-j2-labs>
- [21] Drachsler, H.: Recommender Systems and Learning Analytics in TEL. University Lecture, 2014, stav ze dne 24.4.2012. Dostupné z: <http://www.slideshare.net/Drachsler/rec-sys-mupplelecturekmi>
- [22] Fielding, R. T.: *Architectural Styles and the Design of Network-based Software Architectures*. Dizertační práce, 2000, aAI9980887.

-
- [23] Hlaváč, V.: Učení bez učitele. University Lecture, 2014, stav ze dne 24.4.2012. Dostupné z: <http://cmp.felk.cvut.cz/~hlavac/Public/TeachingLectures/UceniBezUcitele.pdf>
- [24] Jacobi, J.; Benson, E.; Linden, G.: Personalized recommendations of items represented within a database. Září 26 2006, uS Patent 7,113,917. Dostupné z: <http://www.google.com/patents/US7113917>
- [25] Jakob, M.: Reinforcement Learning. University Lecture, 2010, stav ze dne 24.4.2012. Dostupné z: https://cw.felk.cvut.cz/wiki/_media/courses/a3m33ui/prednasky/files/ui-2010-p11-reinforcement_learning.pdf
- [26] John Gantz, D. R.: Extracting Value from Chaos. [online], červen 2011. Dostupné z: <http://www.emc.com/collateral/analyst-reports/idc-extracting-value-from-chaos-ar.pdf>
- [27] Linden, G.; Jacobi, J.; Benson, E.: Collaborative recommendations using item-to-item similarity mappings. Červenec 24 2001, uS Patent 6,266,649. Dostupné z: <https://www.google.com/patents/US6266649>
- [28] Liu, J.; Pedersen, E.; Dolan, P.: Personalized News Recommendation Based on Click Behavior. In *2010 International Conference on Intelligent User Interfaces*, 2010.
- [29] Musto, C.: Apache Mahout – Tutorial (2014). [online], stav ze dne 27.4.2012. Dostupné z: <http://www.slideshare.net/Cataldo/apache-mahout-tutorial-recommendation-20132014>
- [30] Prize, N.: The Netflix Prize Rules. [online], stav ze dne 28.4.2012. Dostupné z: <http://www.netflixprize.com/rules>
- [31] Vitvar, T.: Lecture 5: Application Server Services. University Lecture, 2014, stav ze dne 24.4.2012. Dostupné z: <http://humla.vitvar.com/slides/mdw/lecture5-1p.pdf>
- [32] Vychodil, V.: Komunikace pomocí Socketu. [online], stav ze dne 27.4.2012. Dostupné z: <http://vychodil.inf.upol.cz/publications/white-papers/socket-referat.pdf>
- [33] Vychodil, V.: Pravděpodobnost a statistika: Normální rozdělení a centrální limitní věta. [online], stav ze dne 26.4.2012. Dostupné z: <http://vychodil.inf.upol.cz/kmi/pras/pr09.pdf>
- [34] Wikipedia: Inverted index — Wikipedia, The Free Encyclopedia. 2014, [Online; stav z 27. dubna 2014]. Dostupné z: http://en.wikipedia.org/w/index.php?title=Inverted_index&oldid=591814302

- [35] Wikipedia: Long tail — Wikipedia, The Free Encyclopedia. 2014, [Online; stav z 19. dubna 2014]. Dostupné z: http://en.wikipedia.org/w/index.php?title=Long_tail&oldid=603431399
- [36] aihorizon: Your Online Artificial Intelligence Resource: Machine Learning, Part I: Supervised and Unsupervised Learning. [online], stav ze dne 24.4.2012. Dostupné z: http://www.aihorizon.com/essays/generalai/supervised_unsupervised_machine_learning.htm
- [37] Černý, D.: Bayesovská statistika: klíč k porozumění vesmíru? [online], stav ze dne 26.4.2012. Dostupné z: http://gchd.cz/fygyz/2012_2013/david_cerny-bayesovska_statistika.pdf

Seznam použitých zkratk

IDC

CTO

MIT

ACM Association for Computing Machinery

ICWSM

ICML

IBM

REST

API

TCP

DBMS

NoSQL

MQ

JVM

JSON

URL

ORP

HTTP

Obsah přiloženého CD

	readme.txt.....	stručný popis obsahu CD
	exe.....	adresář se spustitelnou formou implementace
	src	
	impl.....	zdrojové kódy implementace
	thesis.....	zdrojová forma práce ve formátu \LaTeX
	text	text práce
	thesis.pdf.....	text práce ve formátu PDF
	thesis.ps	text práce ve formátu PS