

Sem vložte zadání Vaší práce.

ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ V PRAZE
FAKULTA INFORMAČNÍCH TECHNOLOGIÍ
KATEDRA SOFTWAREVÉHO INŽENÝRSTVÍ



Diplomová práce

Adaptibilní systém pro doporučování obsahu

Bc. Jan Bouchner

Vedoucí práce: Ing. Jaroslav Kuchař

21. dubna 2014

Poděkování

Chci upřímně poděkovat všem, kteří mi věnovali čas, když jsem potřeboval pomoc při psaní této diplomové práce, především vedoucímu práce Ing. Jaroslavu Kuchaři za správné směrování, celkový vhled do technologií a cenné komentáře. Děkuji také své rodině a přátelům za bezvýhradnou podporu během celých mých studií.

Prohlášení

Prohlašuji, že jsem předloženou práci vypracoval(a) samostatně a že jsem uvedl(a) veškeré použité informační zdroje v souladu s Metodickým pokynem o etické přípravě vysokoškolských závěrečných prací.

Beru na vědomí, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., autorského zákona, ve znění pozdějších předpisů. V souladu s ust. § 46 odst. 6 tohoto zákona tímto uděluji nevýhradní oprávnění (licenci) k užití této mojí práce, a to včetně všech počítačových programů, jež jsou její součástí či přílohou a veškeré jejich dokumentace (dále souhrnně jen „Dílo“), a to všem osobám, které si přejí Dílo užít. Tyto osoby jsou oprávněny Dílo užít jakýmkoli způsobem, který nesnižuje hodnotu Díla a za jakýmkoli účelem (včetně užití k výdělečným účelům). Toto oprávnění je časově, teritoriálně i množstevně neomezené. Každá osoba, která využije výše uvedenou licenci, se však zavazuje udělit ke každému dílu, které vznikne (byť jen zčásti) na základě Díla, úpravou Díla, spojením Díla s jiným dílem, zařazením Díla do díla souborného či spracováním Díla (včetně překladu), licenci alespoň ve výše uvedeném rozsahu a zároveň zpřístupnit zdrojový kód takového díla alespoň srovnatelným způsobem a ve srovnatelném rozsahu, jako je zpřístupněn zdrojový kód Díla.

V Praze dne 21. dubna 2014

.....

České vysoké učení technické v Praze
Fakulta informačních technologií

© 2014 Jan Bouchner. Všechna práva vyhrazena.

Tato práce vznikla jako školní dílo na Českém vysokém učení technickém v Praze, Fakultě informačních technologií. Práce je chráněna právními předpisy a mezinárodními úmluvami o právu autorském a právech souvisejících s právem autorským. K jejímu užití, s výjimkou bezúplatných zákonných licencí, je nezbytný souhlas autora.

Odkaz na tuto práci

Bouchner, Jan. *Adaptibilní systém pro doporučování obsahu*. Diplomová práce. Praha: České vysoké učení technické v Praze, Fakulta informačních technologií, 2014.

Abstract

Sem doplňte ekvivalent abstraktu Vaší práce v angličtině.

Keywords Nahradte seznamem klíčových slov v angličtině oddělených čárkou.

Abstrakt

V několika větách shrňte obsah a přínos této práce v češtině. Po přečtení abstraktu by se čtenář měl mít čtenář dost informací pro rozhodnutí, zda chce Vaši práci číst.

Klíčová slova Nahradte seznamem klíčových slov v češtině oddělených čárkou.

Obsah

Úvod	1
Motivace	3
Projekt	3
Struktura práce	4
1 Aktuální stav na poli doporučování	5
1.1 Příklady systémů	5
1.2 Technologické pozadí	10
1.3 Adaptibilní systémy	10
2 Analýza a návrh řešení	11
2.1 Cíle	11
2.2 Požadavky	11
2.3 Sada algoritmů	12
2.4 Rozhraní	12
3 Adaptibilní systém	13
3.1 Strojové učení	13
3.2 Multi-armed Bandit algoritmus	14
3.3 Bayesian Bandits	16
4 Realizace	19
4.1 Principy a technologie	19
4.2 Návrh architektury	20
4.3 Server	20
4.4 Klient	20
4.5 Návrh komunikace	20
5 Experimenty a vyhodnocení	21
5.1 Testování různých způsobů chování	21

5.2	Experimenty	21
5.3	Zhodnocení aplikace	21
5.4	Budoucí práce	21
Závěr		23
Literatura		25
A Seznam použitých zkratk		27
B Obsah přiloženého CD		29

Seznam obrázků

0.1	Příklad rozdělení zobrazující popularitu hodnocení	2
-----	--	---

Úvod

“We are leaving the age of information and entering the age of recommendation”.

Hned na úvod práce jsem si dovolil vypůjčit citát z článku *The Long Tail* [9] (česky Dlouhý chvost) bývalého šéfredaktora časopisu Wired Chrise Andersona, který je též autorem stejnojmenné teorie. Ta je založena na tom, že díky internetu lze nabízet širokou škálu produktů, které by dříve mohly jen sotva slavit prodejní úspěchy, neboť poptávka po nich je příliš malá.

Co je míněno tvrzením „které by dříve mohly jen sotva slavit prodejní úspěchy“ je vysvětleno v následující podsekci Lidstvo a informace, po kterémžto vysvětlení bude vše zasazeno do kontextu zmíněné teorie (podsekce Informace a The Long Tail Theory) a její souvislosti s potřebou doporučování informací, jež je popsána v podsekci Doporučovací systémy.

Lidstvo a informace

Význam informací a dat je pro lidstvo odjakživa nezpochybnitelný. Již před nástupem digitálního věku byl jejich objem velký, takže ke spoustě informací, na základě kterých by si byl jednotlivec utvořil vlastní názor, nebylo snadné se dostat. Lidé se často spoléhali na obecnou oblíbenost daného produktu (ať už se jednalo o zboží, článek, hudebního interpreta a jiné), která byla ale spíše než cokoliv jiného určena aktuálním společenským trendem nebo informace čerpali ze zkušeností svých několika známých na základě jejich doporučení.

S masovým rozvojem internetu pak začalo množství dostupných informací růst obřím tempem (organizace IDC došla v článku *Extracting Value from Chaos* [11] k závěru, že objem světových dat se každé dva roky zdvojnásobuje). Nové informace jsou produkovány takřka každou sekundu a na jejich seřídění máme mnohem méně času než dříve. Není již v lidských silách udržet si o všem přehled. Takovým vývojem se přirozeně změnil pohled na data. Cílem není shromáždit co největší objem, neboť při tomto pokusu bychom



Obrázek 0.1: Příklad rozdělení zobrazující popularitu hodnocení. Zdroj: <http://en.wikipedia.org/> [13]

se zanedlouho dostali do stavu informačního zahlcení. Ceněnou schopností je naopak vytěžít maximální množství užitečných informací a ty využít pro získání nových vědomostí a alespoň přibližně správnou odpověď na potřeby konkrétního jedince.

Informace a The Long Tail Theory

Vrátím se nyní ještě jednou k teorii Dlouhého chvostu. Pro účely této práce ji nemá význam vysvětlovat dopodrobna, ale je vhodné zmínit alespoň hlavní myšlenku, která vychází z úvah výše. Nejdůležitějším poznatkem je to, že – z pohledu obchodního – s nárůstem informací dochází k fenoménu snižování prodejů dřívějších hitů (tedy těch několika málo produktů, které se na daném trhu dostanou k masovému publiku, a které určuje především trend) ve prospěch prvků nacházejících se v takzvaném dlouhém chvostu. Uživatel se tak může dostat k informacím, ke kterým by se obvyčejným hledáním přes jeden z vyhledávačů třeba nikdy nedostal (pokud by tedy opravdu přesně nevěděl, co hledá). Bližší představu si lze utvořit při pohledu na obrázek 0.1. Na vodorovné ose leží jednotlivé produkty, svislá osa pak znázorňuje objem prodeje (či popularitu). Žlutá část pod grafem vpravo reprezentuje dlouhý chvost (zhruba 80 procent produktů, po kterých je na trhu poptávka v malých objemech). Zelená část nalevo pak znázorňuje těch několik dominujících produktů (označuje se též jako *hlava*). Tento fenomén si lze dost dobře ilustrovat na příkladu hudebního průmyslu, kde díky obrovským databázím interpretů nedochází k selekci a prodeji jen těch potenciálně nejúspěšnějších, ale uživatelům se dostává mnohem větší výběr.

Všechny výše zmíněné faktory zapříčinily rozvoj přístupu zvaného *informační filtrování*. Odtud už je jen krok k doporučování na míru, které se v posledních několika letech rozmohlo zaváděním tzv. *doporučovacích systémů*.

Doporučovací systémy

Doporučovací systémy pracují s předem známými daty a mohou uživateli pomoci v tom smyslu, že z obrovské množiny informací různými způsoby vyfiltrují relevantní podmnožinu. Například sledováním a vyhodnocováním historie používání služby uživatelem (doposud nakoupené produkty, seznam všech jím ohodnocených článků či žebříček preferovaných hudebních interpretů) nebo porovnáváním kontextu uživatele s ostatními lidmi využívajícími tu samou službu. Oběma způsoby je možné objevit pro uživatele zajímavé a jeho vkusu vyhovující položky. Další informace o doporučovacích systémech a aktuální stav na poli doporučovacích systémů včetně technologického pozadí dokumentuje následující kapitola 1.

Motivace

Představme si nyní jakéhosi rádce, který dokáže v každém okamžiku rozhodnout, co je za daných okolností nejvhodnější. Rádce v klidu vyčkává, ale v okamžiku, kdy je tázan uživatelem na to, jakou metodou si má nechat doporučit obsah, aby z toho měl maximální užitek, je schopen ihned a bez dlouhého rozmýšlení odpovědět. Rádce dokáže i pružně reagovat na situaci, kdy náhle dojde ke změně preferencí či vyvstanou jiné nečekané události, které mají za následek doporučení nevhodného obsahu.

Projekt

Cílem práce tedy je navrhnout adaptibilní systém, který bude automaticky vhodně volit a kombinovat algoritmy. Bude využívat zpětnou vazbu ohledně kvality doporučení, která principem odměny za dobré doporučení nebo trestu za špatné ovlivní preference při kombinování. Zároveň bude zodpovědná za podporu velkého množství dotazujících se uživatelů.

Tato diplomová práce dokumentuje návrh a vývoj takového systému a s ním spolupracujících komponent.

TODO Napsat že neméně důležitou součástí práce bylo nastudování dostupných algoritmů a tak... prostě nějaká ta řešerše.

TODO Napsat že důležité bylo to všechno otestovat na reálném příkladu
Toto je seznam modulů, které byly pro potřeby práce vyvinuty:

- **Adaptibilní systém pro doporučování obsahu.** The first item
- **Sada základních algoritmů určených k doporučování.** The second item
- **Rozhraní pro algoritmy a systému pro kombinování.** The third etc ...

Struktura práce

Tato práce je strukturována do X různých kapitol a popisuje celý vývojový cyklus systému. Kapitoly jsou řazeny v tom samém pořadí, v jakém probíhaly vývojové fáze.

Kapitola Experimenty a vyhodnocení The first item

Kapitola 5 The second item

Kapitola The third etc ...

Aktuální stav na poli doporučování

Kamkoliv v dnešní době na internetu zavítáme, máme velkou šanci, že na některý z doporučovacích systémů narazíme. Mohou mít různá jména, ať už *uživatelé A se líbí věc B*, dále například *lidé, které byste mohli znát* nebo třeba *uživatelé kupující produkt X kupují též produkt Y*, ale všechny mají stejný význam – zaujmout či upozornit na něco nebo někoho konkrétního. Spousta elektronických obchodů, renomovaných aukčních domů, ale též serverů se zábavou na nich doslova staví svá podnikání, neboť správně navržený a fungující doporučovací systém může firmě přinést výrazné zvýšení zisku. Sami jejich zákazníci navíc o doporučování stojí. Jsou vděční za navigaci a existuje vysoká pravděpodobnost, že v závislosti na ní budou přizpůsobovat i své chování. Uživatelská trpělivost ale není neomezená – pokud dostávají špatná doporučení, nenásledují je a ve výsledku odmítají celý systém.

1.1 Příklady systémů

Na internetu je k nalezení samozřejmě několik desítek, ba možná i stovek, běžících systémů, záměrně jsem se proto snažil vybrat jen zlomek z nich pokrývající ale většinu doporučovaného obsahu (zboží, zábava, text). Níže uvádím jako příklady několik úspěšně nasazených systémů do reálného provozu.

1.1.1 Amazon.com

Amazon.com, Inc. je jedním z nejstarších a největších internetových prodejců. Společnost začínala svůj provoz jako online knihkupectví, ale postupem let zařadila do své prodejní nabídky též hudební a filmové nosiče, software, elektroniku, nábytek a spoustu dalšího zboží. Novinkou posledních let je vlastní spotřební elektronika v podobě čtečky elektronických knih a tabletů Kindle či poskytování služeb z oblasti cloud computingu.

1. AKTUÁLNÍ STAV NA POLI DOPORUČOVÁNÍ

Firmu lze řadit mezi průkopníky doporučování na internetu. Jako jeden z prvních internetových prodejců totiž začala svým zákazníkům doporučovat výrobky na základě nákupů jiných uživatelů.

Doporučovací systém je založen na několika zdrojích informací:

- porovnávání uživatelem prohlížených položek a položek umístěných ve virtuálním nákupním košíku s položkami, které se společně s těmito prohlíženými v minulosti často prodávaly ¹.
- udržování informací ohledně hodnocení položek uživateli
- zaznamenávání historie nákupu (pokud uživatel v minulém měsíci zakoupil tři dětské knížky, znamená to, že má dítě?)
- spousta dalších postupů, jako například vyhodnocování demografických informací (dle doručovací adresy), zaznamenávání pohybu po stránce (jaké všechny položky a kolikrát si uživatel prohlédl, než umístil jednu konkrétní do nákupního košíku) nebo sledování prokliků ² z cílených marketingových e-mailů s odkazy na zboží [3].

Společnost nazývá svou hlavní doporučovací strategii jako *item-to-item kolaborativní filtrování* a používá ji pro přizpůsobení prohlížení webu svým stálým zákazníkům. V tom smyslu, že fanoušek moderních technologií může při své návštěvě stránek nalézt odkazy na technologické novinky všeho druhu, zatímco mladá matka bude mít na těch samých stránkách v nabídce ve větším zastoupení dětské zboží.

Výše jsou popsány pouze základní principy. Doporučovací systém společnosti je samozřejmě velmi komplexní a detailní algoritmus je udržován jako obchodní tajemství. K nahlédnutí jsou ale patenty, např. *Personalized recommendations of items represented within a database* [10] nebo *Collaborative recommendations using item-to-item similarity mappings* [12].

1.1.2 Netflix

Netflix, Inc. je společnost, která začínala nabízet své služby jako internetová videopůjčovna. Během posledních pár let (strategicky významný byl rok 2007, kdy byla nabídka rozšířena o filmy streamované prostřednictvím internetu [5]) se rozrostla v obrovskou mediální společnost nabízející obsah v podobě filmů a seriálů pro většinu v dnešní době používaných platforem jako PC, Mac, PlayStation3, Wii, Xbox a také mobilní telefony a tablety.

¹affinity analysis – nacházení spojení mezi odlišnými položkami. Základním příkladem budiž vztah mezi šamponem a kondicionérem. Kupující je většinou používá v ten samý čas [7]. Při nákupu jednoho by mohl mít tedy zájem i o druhý.

²Jako proklik se označuje takové kliknutí na odkaz, které uživatele dovede na cílovou stránku [6].

Vzhledem k tomu, že firma staví své podnikání na tom, že přicházející uživatelé platí za konzumaci zábavy (dle [4] pochází 2/3 zapůjčených filmů z předchozího doporučení), je v jejím vlastním zájmu, aby těmto uživatelům sledujícím filmy a seriály nabízela automaticky další obsahově či žánrově podobné, zkrátka takové, jenž budou co možná nejvíce lahodit jejich vkusu. Úspěšné podnikání společnosti je tak přímo závislé na tom, jak kvalitním doporučovacím systém společnost disponuje.

Za tímto účelem byl pro doporučování filmů vyvinut vlastní systém s názvem *Cinematch*. Potřeba neustálého zlepšování a zpřesňování doporučení vyústila v to, že společnost začátkem října 2006 vypsala soutěž známou jako *Netflix Prize*. Jednalo se o pokus ještě více pokročit na poli doporučování filmů a pro tým, který by dokázal zlepšit dosavadní výsledky systému *Cinematch* alespoň o 10 procent, byla vypsána odměna ve výši 1 000 000 dolarů.

K tomuto účelu společnost uvolnila testovací data obsahující ID uživatele, ID filmu, hodnocení na intervalu $<1,5>$ a datum uskutečnění hodnocení. Testovací data obsahovala 100 480 507 hodnocení pro 17 770 filmů od 480 189 uživatelů. Uvolněna byla ještě další testovací data obsahující stejné informace, jen byla vynechána uživatelská hodnocení. Cílem úkolu pak bylo předpovědět tato chybějící hodnocení opět na intervalu $<1,5>$.

Cena byla udělena až v roce 2009 (do té doby docházelo k průběžnému zlepšování, ale nebylo dosaženo stanoveného zlepšení o 10 procent) týmu *Bell-Kor's Pragmatic Chaos* (který vznikl spojením tří do té doby samostatných týmů). Vítězný tým použil k dosažení cíle technik strojového učení, aby při tom zjistil několik zásadních poznatků. Například to, že každé hodnocení filmu je silně subjektivní záležitostí, kterou je dopředu obtížné předpovědět. Ukázalo se také, že velmi záleží na tom, zda uživatel hodnotí právě dosledovaný film nebo film, který zhlédl již před delší dobou. Velkou roli též hraje nálada během dne a další faktory [1].

Výsledný algoritmus je navíc směsicí zhruba stovky menších algoritmů, takže by se dalo s trochou nadsázky prohlásit, že jednou z hlavních taktik je použít tolik doporučovacích algoritmů, kolik je jen možné.

1.1.3 Zite & Flipboard

Zite.com³ je moderní aplikace pro chytré mobilní telefony a tablety.

Mike Klass, CTO společnosti v jednom z článků [8] prozradil, že vizí bylo vyvinout sofistikovaný, na technikách strojového učení postavený systém, jehož účelem nebude pouhé filtrování přichozích novinek vedoucí k úspoře času uživatele. Cílem tohoto systému bylo přizpůsobit se svému uživateli studiem vzorců chování (pozoruje zájmy a návyky při čtení článků) natolik, aby mu dokázal doporučit přesně to, co v danou chvíli hledá, ale kvůli různým okol-

³<http://zite.com>

nostem (například obsah produkovaný neznámým bloggerem) by na to nikdy neměl šanci narazit.

Zite nasazené v systému uživatele je tedy stejně tak unikátní jako jeho uživatel. Sleduje, jaké článků si vybírá ke čtení, jak dlouhé tyto články jsou a jak dlouho stráví uživatel jejich čtením. Systém tedy každý den vyhodnocuje miliony nových článků, přičemž se zaměřuje na typ, klíčové atributy i na to, jakým způsobem je článek sdílen skrze web. Následně využije tyto informace ke spárování vybraných článků s osobním vkusem uživatele a tyto články mu doručí do aplikace.

Tak jako Netflix a Amazon doporučují filmy a produkty, které by na základě podobnosti mohli uživatele zajímat, stejně tak i Zite provádí na pozadí porovnání mezi čtenáři – jak v rámci aplikace, tak obecně na webu.

V srpnu 2011 o technologii vyjádřila zájem společnost CNN [2] a Zite přešlo pod ni. Poslední novinky ze začátku března 2014 ale naznačují [8], že Zite opouští CNN a rozhodlo se spojit síly s aplikací Flipboard ⁴ vývojářské společnosti Flipboard, Inc., jejíž funkcionalitou je agregování obsahu ze sociálních sítí a jiných stránek a následné nabízení ke čtení v magazínovém formátu umožňujícím jednoduchým způsobem listovat napříč vzájemně souvisejícími tématy.

Společným cílem je vystavět nejlepší systém pro personalizované čtení novin.

1.1.4 Mendeley

Mendeley je systém určený k doporučování vědeckých článků, jenž využívá jako svou výpočetní vrstvu technologii Apache Mahout ⁵. Cílem systému je spojovat dohromady výzkumníky a jejich data. Svým uživatelům tak pomáhá v organizaci výzkumu, umožňuje jim nalézt potenciální spolupráci s dalšími uživateli aplikace a napomáhá též k objevům nových podnětů pro vlastní práci. Uživatelé této aplikace jsou přední světové university jako University of Cambridge, Stanford University, MIT či University of Michigan. Data pro aplikaci pocházejí z vlastních importů svými uživateli i z externích importů skrze různé katalogy prací.

Projekt samotný se v jedné ze svých prezentací [?] přirovnává k největší hudební databázi na internetu – last.fm ⁶. Ta funguje na tom principu, že potenciální uživatel si nainstaluje na svůj počítač desktopovou aplikaci, následně s instalovanou aplikací začne poslouchat hudbu a tím je zahájeno automatické odesílání informace o skladbě (interpret, žánr apod.) na server last.fm. Podle těchto odeslaných dat jsou uživateli v budoucnu doporučovány další skladby.

Mendeley tuto analogii vysvětluje tím, že hudební knihovny jsou v jeho případě výzkumné knihovny, roli interpretů zde zastávají jednotliví výzkum-

⁴<https://flipboard.com>

⁵<https://mahout.apache.org>

⁶<http://www.last.fm>

níci, hudební skladby jsou pak jimi publikované články a jednotlivé hudební žánry reprezentují vědecké disciplíny.

Doporučení jsou zde generována dvojím způsobem.

Kolaborativní filtrování Používá se pro personalizované doporučení. Podporována je jak user-based, tak i item-based varianta doporučení.

Filtrování založené na obsahu Používá se k nalezení souvisejícího výzkumu, například nalezení článku ze stejné výzkumné kategorie nebo článku s podobným názvem.

Uživatelé mohou svůj zájem či nezájem o každou z doporučených položek vyjádřit zpětnou vazbou, která je dvojího typu:

Accept Vyjadřuje, že uživatel s daným doporučením souhlasí nebo pro něj vylo nějakým způsobem užitečné.

Remove Vyjadřuje nevhodné doporučení. Uživatel touto volbou dává najevo, že podobné doporučení by raději již příště nedostal.

1.1.5 Google News

1.1.6 Výzkum

Také výzkum v oblasti doporučovacích systémů, zdá se, nezahálí. Zde je výčet několika akcí, jejichž náplní či součástí je problematika doporučování a doporučovacích systémů.

- **ACM RecSys conference.** ⁷ Tato konference je předním mezinárodním fórem pro prezentaci nových výsledků výzkumu, systémů a postupů na poli doporučovacích systémů. RecSys sdružuje hlavní mezinárodní výzkumné skupiny a též mnoho předních světových společností na trhu e-commerce. Nabízí také doprovodný program v podobě zvaných přednášek, konzultace týkající se této problematiky a sympózií studentů doktorských programů.
- **ICWSM: Weblog and Social Media.** ⁸ The International AAAI Conference on Weblogs and Social Media je mezinárodní konference, na které se střetávají výzkumní pracovníci z oblasti počítačových a společenských věd. Konference je pořádána za účelem sdílení znalostí, diskutování o nápadech a výměny informací. Probíranými body jsou psychologické a sociální teorie, výpočetní algoritmy pro analýzu sociálních médií a jedním z mnoha témat jsou též doporučovací systémy.

⁷<http://recsys.acm.org>

⁸<http://www.icwsml.org/2014>

- **ICML: Machine Learning.** ⁹ The International Conference on Machine Learning je konference s bohatou historií. Její první ročník proběhl již v roce 1980 v Pittsburghu. Jedná se o přední mezinárodní konferenci zabývající se strojovým učním.

O tématu se též píše spousta článků a každým rokem vzniká několik disertačních prací. Dle dostupných informací z ACM RecSys Wiki ¹⁰ jich jen za poslední 4 roky bylo přes 50.

1.2 Technologické pozadí

Napsat, že používají ty a ty algoritmy, takže na jejich základě jsem se rozhodl vybrat ty a ty a implementoval je. Jejich popis a vysvětlení do hloubky viz nějaký ref.

TODO

1.2.0.1 Typy

Doporučovací systémy lze dle způsobu práce rozdělit do dvou skupin. behavioral (založeny na interakci uživatelů se články) - most popular, collabo. filter., item to item a content (založeny na člancích) - content similarity, latest item zmínit nejznámější doporučovací algoritmy, collaborative filtering, most popular, text similarity atd. ze treba pro potreby doporučovani novinek je lepsi kolaborativni filtrovani a ze pro doporučovani obsahu je lepsi text similarity

content based - TF_IDF, BM25, bayesovské kalsifikátory... rychle avsorbovani novych polozek, prekonani cold start problemu, lze uz z malo prikladu stavet dobre doporučení

collfiltr- zadna potreba rozumet item charekteristikam

1.3 Adaptibilní systémy

Jak vidno, podobných řešení je celá řada. Mou největší inspirací a výzvou, ke které bych se rád přiblížil, je open recommendation platform společnosti plista.

⁹<http://icml.cc/2014>

¹⁰http://www.recsyswiki.com/wiki/List_of_recommender_system_dissertations

Analýza a návrh řešení

Zatímco v předchozí kapitole jsem se zabýval analýzou existujících řešení a zjišťoval, jaké funkce jsou současnými doporučovacími systémy nabízeny, tato kapitola je celá věnována analýze mnou řešeného systému. Ta v sobě zahrnuje definování cílů a požadavků, které by měl systém plnit. Na základě této analýzy byl poté proveden návrh řešení.

Jednou z mnoha výzev pro někoho, kdo se snaží vybudovat doporučovací systém, je to, že je velice těžké dopředu říct, zda budou naše předpovědi dost přesné. Alespoň do té doby, dokud je nezačneme dělat a nebudeme pozorovat, jak často naši uživatelé přijímají naše návrhy. Je zde obrovský prostor možností (možných metod), z čeho vybírat.

2.1 Cíle

Prvním a nejdůležitějším cílem je navrhnout a vyvinout systém, který bude automaticky vhodně volit a kombinovat algoritmy.

Druhým cílem je identifikovat a následně implementovat sadu základních algoritmů určených pro kombinování. Pomocí této sady bude možné

Třetím cílem je vyvinout buď dashboard nebo nevim...

2.2 Požadavky

Hlavním požadavkem pro systém je

2.2.1 Nefunkční požadavky

2.2.2 Funkční požadavky

Pro implementaci rozhodovacího mechanismu je potřeba

Tato část práce mi přišla natolik významná, že jsem se jí rozhodl věnovat samostatnou kapitolu 3.

2.2.3 Real time

live read + live write = real time recommendation <http://www.slideshare.net/d0nut/realtime-recommender-with-redis-hands-on>

2.2.3.1 Důraz na zpětnou vazbu

počet kliků, objednávek, čas na stránce...

2.2.3.2 Jednoduchý průzkum

mezi price/time my plýtváme na offline evaluaci a price je kvůli špatným doporučením ztrácena

2.3 Sada algoritmů

Identifikujte sadu základních algoritmů určených pro kombinování. Ty implementujte nebo použijte existující implementace.

2.4 Rozhraní

Identifikujte sadu základních algoritmů určených pro kombinování. Ty implementujte nebo použijte existující implementace.

Adaptibilní systém

Navrhněte, implementujte a otestujte systém, který bude dynamicky kombinovat algoritmy a optimalizovat celkovou kvalitu algoritmů.

3.1 Strojové učení

Vzhledem k povaze řešeného problému je nutné zaměřit se na metody tzv. *strojového učení*. Jedná se o vědeckou disciplínu (jednu z větví oboru umělé inteligence), která se zabývá tím, jak se má počítač přizpůsobit určité situaci, aniž by byl pro danou situaci explicitně naprogramován. Metody strojového učení, které hledají generalizaci libovolných dat nebo slouží pro adaptaci existujícího systému na změny okolí, se používají ve všech oblastech informačních věd od analýzy snímků, analýzy DNA a textu, až po simulace chování člověka.

Typickým příkladem je vytvořit z dostupných dat model, který dokáže:

- predikovat cenu akcií za 6 měsíců z aktuální výkonnosti společnosti a ekonomických dat
- rozpoznat spam od regulérního e-mailu
- u pacienta hospitalizovaného s infarktem predikovat riziko dalšího infarktu
- napomoci společnostem zabývajících se internetovou reklamou v rozhodování se, kterou reklamní strategii použít k maximalizaci zisků Používá to ale třeba Google analytics! při správě online experimentů https://support.google.com/analytics/answer/2844870?hl=cs&ref_topic=2844866

Algoritmy strojového učení mohou být děleny do taxonomie (nadtříd a podtříd) založené na požadovaném výsledku algoritmu nebo typu vstupu, který je k dispozici během trénování stroje. Algoritmů je celá řada, bude tedy vhodné zmínit zde alespoň ty nejtypičtější.

Supervised learning ¹¹ TODO

Unsupervised learning ¹² TODO

Reinforcement learning ¹³ TODO

TODO zmínit, že pro naše potřeby je nejvhodnější reinforcement learning.

http://cs.wikipedia.org/wiki/Strojov%C3%A9_u%C4%8Den%C3%AD http://cs.wikipedia.org/wiki/Zp%C4%9Bnovazebn%C3%AD_u%C4%8Den%C3%AD http://en.wikipedia.org/wiki/Machine_learning http://cs.wikipedia.org/wiki/U%C4%8Den%C3%AD_s_u%C4%8Ditelem http://en.wikipedia.org/wiki/List_of_machine_learning http://en.wikipedia.org/wiki/Reinforcement_learning <http://tdunning.blogspot.cz/2012/10/references-for-on-line-algorithms.html> <http://tdunning.blogspot.cz/search?q=bandit> <http://camdp.com/blogs/multi-armed-bandits> <http://www.recsyswiki.com/wiki/Ensemble>

Algoritmus začne ve stavu nevědomí (ignorant state), kdy neví nic o daných okolnostech a začíná nabývat vědomostí tím, že testuje systém. Tím, jak vstřebává data a vyhodnocuje výsledky, učí se, jaké chování je nejlepší.

Z psychologického hlediska se jedná o následující úvahu: Jakým způsobem dokáže trest a odměna ovlivňovat naše budoucí chování? Na základě čeho se (nejen) lidstvo učí novým věcem?

3.1.1 Online učení

Navrhovaná strategie je též nazývána jako *online učení*. Nutno zmínit, že slovem online zde není míněno něco ve smyslu internetu, ale ve smyslu neustále se vyvíjející aktualizace dat. Učící algoritmus v každém kole vykoná nějakou akci, přijme zpětnou vazbu a připíše si daný zisk či ztrátu.

Z matematického hlediska má online učení propojení na klasické online algoritmy, teorii (opakovaných) her a teorii pravděpodobností. Díky těmto znalostem tak můžeme navrhovat pravděpodobností dynamické systémy, kterými lze modelovat složitá průmyslová zařízení nebo třeba výherní automat známý jako mnohoruký bandita (Multi-Armed Bandit).

3.2 Multi-armed Bandit algoritmus

The Multi-Armed Bandit Problem je jedním z klasických problémů online učení. Tato herní strategie je podobná tradičnímu hernímu automatu, který představuje one-armed strategii, ale mnohoruká varianta má více herních pák *V každém kole si lze pro hru vybírat mezi N automaty.*

¹¹učení s učitelem

¹²učení bez učitele

¹³zpětnovazební učení nebo též učení posilováním

3.2.1 Princip algoritmu

Strategii si lze představit tak, že stojíme před N výherními automaty (též nazývány jako bandité) a v každém kole máme možnost vybrat si jeden z nich, na kterém budeme hrát. Pravděpodobnosti výher u jednotlivých automatů jsou pro nás neznámé.

Formálně lze strategii popsat jako skupinu výnosových (reward) distribučních funkcí $B = R_1, \dots, R_K$, kde K je počet banditů. Každý bandita má tedy přiřazenu jednu distribuční funkci, jež vyjadřuje pravděpodobnost úspěchu.

Zpočátku nemá hráč žádnou informaci o průběhu hry ani o rozložení pravděpodobnosti úspěchu napříč bandity. Tím, že v každém kole vybíráme vždy jen jednoho banditu, se snažíme navrhnout strategii pro maximalizaci celkové výhry.

Samozřejmě, že kdybychom znali banditu s největší pravděpodobností výhry, potom bychom jej vždy vybírali, čímž bychom maximalizovali výhry. Naším úkolem bude tedy nalézt nejlepšího banditu a to co nejrychleji, jak je to jen možné.

K návrhu strategie nám pomáhá to, že jednotlivé bandity nejdříve testujeme, abychom získali nutné znalosti. Poté už se lze zaměřovat na páky, které nám poskytují největší užitekované znalosti.

Úkol trochu komplikuje stochastická povaha banditů. Suboptimální bandita může vracet spoustu výher, což by nás mohlo přimět uvěřit, že právě tento bandita je velice štědrý. Podobně ale naopak nejlepší bandita může vracet spoustu proher. Měli bychom tedy pořád zkoušet i lůzry, nebo se na ně vykašlat?

Co je dalším problémem, tak pokud najdeme banditu, který vrací “docela dobré” výsledky, měli bychom toto zachovat a nadále rozvíjet naše “docela dobré” skóre, nebo bychom měli zkoušet i další bandity v naději, že nalezneme ještě lepšího? Tomuto se říká exploration vs. exploitation dilemma.

NEMOJE Necht u_1, \dots, u_K jsou průměrné hodnoty výnosových distribučních funkcí. Hráč aktivně zatáhne za páku každé kolo a sleduje příslušný výnos. jeho úkolem je maximalizovat součet těchto výnosů. Oželení (regret) po T kolech je definováno jako rozdíl mezi součtem výnosů příslušných výnosových funkcí optimální strategie a součtu získaných výnosů (VZOREC VIZ kybernář)

3.2.2 Exploration vs. Exploitation

- **Explorace** Nacházení nových oblastí hledání - náhodné procházky, nevyužívá předchozích znalostí
- **Exploatace** Využití stávajících znalostí, uvíznutí v lokálních extrémech, rigidita

3.3 Bayesian Bandits

Ukazuje se ale, že nalézt optimální řešení je neuvěřitelně obtížné. A může trvat léta, než je celkové řešení vyvinuto. Existuje totiž také spousta přibližně optimálních řešení, které jsou docela dobré.

Právě to jedno z mnoha takových řešení (které lze velice dobře škálovat) je známo jako Bayesian Bandits a bude se jednat o online algoritmus, o kterém už padla řeč v sekci ?? a má přímou souvislost s zpětnovazebním učením (reinforcement learning).

NEMOJE PRUBEH ALGORITMU Bayesovské řešení začíná stanovením pravděpodobností výhry pro každého banditu z předchozích zkušeností. V našem případě jsou tyto pravděpodobnosti od 0 do 1.

Prior a posterior by Verča "před provedením pokusu"- např. pravděpodobnost, že hodím sudý číslo na kostce je $1/2$, a "aposteriori" je po provedení pokusu - nedřív uděláš pokus - to se používá třeba u Bayesova vzorce. ale tý tabulce upřímně moc nerozumím... to prior má být asi jakože to, co předpokládáš, že bys měl mít a to posterior je, jak to jakože "odhadneš" třeba zdat - jakože pokusem

V každém kole: Vzorkování náhodné veličiny X_b Výběr bandity s největším vzorkem (např. vyber banditu $B = \operatorname{argmax} X_b$) Pozorujme výsledek vybraní bandity B a updatujme priors (takový ty prostě věci z dřívějšího vyhodnocování - pokusy a výhry) Návrat na 1)

A to je vše. Z výpočetního hlediska algoritmus zahrnuje vzorkování z N distribucí. Počáteční priors jsou $\text{Beta}(\alpha = 1, \beta = 1)$ (uniformní rozdělení) a pozorovaná náhodná veličina X (výhra či prohra, zakódována jako 1, respektive 0) je Binomialní, proto posterior (po provedení pokusu) je $\text{Beta}(\alpha = 1 + X, \beta = 1 + 1 - X)$

Takže pokud bychom měli odpovědět na otázku z dřívějška (zda vybírat i ty lůzry), tak tento algoritmus navrhuje to, abychom nevyřazovali lůzry, ale měli bychom je vybírat s klesajícím tempem, jakmile nashromáždíme dost jistoty, že existují lepší bandité. Vyplývá to z podstaty, že vždy existuje nenulová šance, že lůzr dosáhne statusu B , ale pravděpodobnost této události se snižuje s tím, jak hrajeme více kol.

TODO možná nějaký obrázky (grafy) jak se to pulls vyvíjí (všechno je v článku na campdb)

Všimněme si, že se zase až tolik nestaráme o nějaké závěry nad skrytými pravděpodobnostmi, spíše se pro tento problém zabýváme o výběr nejlepšího bandity (nebo přesněji slovy, stále jistějšího během vybírání banditů)

To je třeba vidět v tom grafu níže, že distribuce červeného bandity je velice široká (což představuje neznalost o tom, jaká by skrytá pravděpodobnost vůbec mohla být), ale jsme si docela dobře jistí, že není nejlepší, algoritmus se tedy rozhodne tohoto banditu ignorovat.

ZPETNA VAZBA Multi-armed bandit je příklad Single-stage typu Reinforcement learningu (viz https://cw.felk.cvut.cz/wiki/_media/courses/

a3m33ui/prednasky/files/ui-2010-p11-reinforcement_learning.pdf). Tedy snažíme se po jedné akci ihned uplatňovat feedback. Každá akce v multi-armed je nazývána jako jedna hra. Po každé hře a_t obdržíme (stochastický) reward r_t : $E[r_t|a_t] = Q^*(a_t)$ a z dlouhodobého hlediska je právě cílem maximalizovat reward. “To solve the multi-armed bandit problem, one must explore a variety of actions and exploit the best of them”

$Q^*(a)$ je “action-value odhad - v čitateli součet rewardu z jednotlivých výběrů / počet výběrů

Pak je ještě “greedy akce” ve hře t - $a_t^* = \arg\max_a Q_t(a)$

Zajímavé poznámky V případě jakéhokoliv úspěchu doporučení by se měla navýšit někde hodnota pravděpodobnosti, se kterou bude algoritmus znovu vybrán. V případě neúspěchu pak by se tato pravděpodobnost měla exponenciálně snížit. V další iteraci už se bude systém rozhodovat s touto pravděpodobností mezi objevováním a zužitkováním. V případě zužitkování se vybírá z algoritmů, co již předtím něco vynesly. To je ta strategie learnable - u banditů to funguje tak, že poměr mezi objevováním a zužitkováním se mění v čase a ne v závislosti na předchozích výsledcích. Algoritmy jsou rozděleny ve svých dimenzích a každé té dimenzi je přiřazena určitá pravděpodobnost definující míru úspěšnosti nalezení toho, že tenhle algoritmus je fakt nejlepší. V případě, že uživatelé zužitkovávají tyto znalosti, tak si poté vybírají algoritmus, který má maximální pravděpodobnost z dané množiny. epsilon greedy!!!! - varianta epsilon decreasing Jak to má kybernetik: Je-li pirát ve stavu objevování, tak v případě útoku na loď nalezne příslušný prostor, který obsahuje místo útoku, a zvýší mu hodnotu pravděpodobnosti. Když je ve stavu zužitkování znalostí, tak pluje do prostoru, kde hledá transportní loď. V případě, že za celý cyklus nenalezne žádnou loď, tak se exponenciálně sníží hodnota pravděpodobnosti daného prostoru. Nalezne-li loď, tak zvýšení pravděpodobnosti proběhne jako ve stavu objevování.

ZAVEREM Algoritmus je velice jednoduchý, proto je také jednoduché jej rozšířit. V mém případě bylo potřeba přidat learning rates - předpokládejme, že to prostředí se prostě může měnit v čase. Technicky by se tedy standardní Bayesian Bandit algoritmus self-updatoval tím, že by se učil tím, že to, co si myslel, že se zdá jako nejlepší, selhává nejčastěji. Také lze docílit toho, aby se algoritmus učil měnícím se prostředím rychleji. Potřebuje pro to jedinou věc - přidat rate napříč updatováním.

Pokud rate menší než 1, algoritmus bude zapomínat předchozí výsledky rychleji a tlak na neznalost bude směrem dolů. naopak rate větší než 1 implikuje to, že náš algoritmus se bude chovat více riskantně a bude vsázet na dřívější výhry častěji a bude tedy více odolný proti změnám měnícího se prostředí.

Realizace

Realizace toho systému, jak jsem ty části propojil dohromady a tak

4.1 Principy a technologie

Analýza a návrh systému pro kombinování metod pro doporučování obsahu v reálném čase

Sekce se zabývá výběrem vhodných technologií REST, Aplikační server, NoSQL, ZeroMQ, Hadoop, Apache mahout

`http://contest.plista.com/wiki/example`

4.1.1 Vyhodnocovací technologie

Výpočty. kvůli kombinování budeme počítat s floaty

4.1.2 Server

Je třeba nějaký server, na kterém to bude běžet

4.1.3 Api

4.1.4 Jak to udělat, aby to běželo rychle?

musíme zpracovávat data velice rychle rychlý webový server, rychlý síťový protokol, rychlou frontu zpráv, rychlé úložiště

4.2 Návrh architektury

4.3 Server

4.3.1 Parametrizace

volba parametrů, ať už těch, co ovlivňují tresty nebo třeba úložiště (redis...)

4.4 Klient

4.5 Návrh komunikace

router, dealer, worker thready

4.5.1 Formát zasílaných zpráv

4.5.2 Komunikační protokol

Experimenty a vyhodnocení

kecy o testování

5.1 Testování různých způsobů chování

viz jak jarda vymyslel těch zhruba 5 příkladů, co mohou nastat

5.2 Experimenty

5.3 Zhodnocení aplikace

Slovní zhodnocení

5.4 Budoucí práce

bude li nějaká

Závěr

Literatura

- [1] BellKor, AT&T Labs, Inc. – Research. [online], stav ze dne 21.4.2012. Dostupné z: <http://www2.research.att.com/~volinsky/netflix/>
- [2] CNN Acquires Zite. [online], stav ze dne 21.4.2012. Dostupné z: <http://cnnpressroom.blogs.cnn.com/2011/08/30/cnnzite/>
- [3] How does the Amazon Recommendation feature work? [online], stav ze dne 21.4.2012. Dostupné z: <http://stackoverflow.com/questions/2323768/how-does-the-amazon-recommendation-feature-work>
- [4] Netflix Contest: 1 Million Dollars for Better Recommendations. [online], stav ze dne 21.4.2012. Dostupné z: <http://www.uie.com/brainsparks/2006/10/02/netflix-contest-1-million-dollars-for-better-recommendations/>
- [5] Netflix offers streaming movies to subscribers. [online], stav ze dne 21.4.2012. Dostupné z: <http://arstechnica.com/uncategorized/2007/01/8627/>
- [6] Proklik. [online], stav ze dne 21.4.2012. Dostupné z: <http://www.adaptic.cz/znalosti/slovnicek/proklik/>
- [7] What Is Affinity Analysis? [online], stav ze dne 21.4.2012. Dostupné z: <http://www.wisegeek.com/what-is-affinity-analysis.htm>
- [8] Zite is Flipping out. [online], stav ze dne 21.4.2012. Dostupné z: <http://blog.zite.com/2014/03/05/zite-is-flipping-out/>
- [9] Anderson, C.: The Long Tail. [online], říjen 2004. Dostupné z: <http://archive.wired.com/wired/archive/12.10/tail.html>
- [10] Jacobi, J.; Benson, E.; Linden, G.: Personalized recommendations of items represented within a database. Září 26 2006, uS Patent 7,113,917. Dostupné z: <http://www.google.com/patents/US7113917>

LITERATURA

- [11] John Gantz, D. R.: Extracting Value from Chaos. [online], červen 2011. Dostupné z: <http://www.emc.com/collateral/analyst-reports/idc-extracting-value-from-chaos-ar.pdf>
- [12] Linden, G.; Jacobi, J.; Benson, E.: Collaborative recommendations using item-to-item similarity mappings. Červenec 24 2001, uS Patent 6,266,649. Dostupné z: <https://www.google.com/patents/US6266649>
- [13] Wikipedia: Long tail — Wikipedia, The Free Encyclopedia. 2014, [Online; stav z 19. dubna 2014]. Dostupné z: http://en.wikipedia.org/w/index.php?title=Long_tail&oldid=603431399

Seznam použitých zkratk

GUI Graphical user interface

XML Extensible markup language

Obsah přiloženého CD

	readme.txt.....	stručný popis obsahu CD
	exe	adresář se spustitelnou formou implementace
	src	
	impl.....	zdrojové kódy implementace
	thesis	zdrojová forma práce ve formátu \LaTeX
	text	text práce
	thesis.pdf	text práce ve formátu PDF
	thesis.ps	text práce ve formátu PS